


2장 - (4). 신경망



멘토 이현수

1. 신경망의 정의

<머신러닝 첫 단추 끼우기>
4.1.절

- 신경망의 정의

신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 정의

- Neural Network (NN)
- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델
- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 수학적 함수
- 신경망을 사용할 경우, 충분한 관계가 표현 되는지 보장되는가?
→ Universal Approximation Thm. (교육자료 참고)

2. 신경망의 구조 (1)

<머신러닝 첫 단추 끼우기>
4.2.절

신경망의 정의

• 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를
하나의 함수 관계로 연결해 표현해주는 인공지능 모델

- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 **수학적 함수** $F(\mathbf{x})$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

비선형 함수

m차원
실벡터

(0, 1, 4, 5, ... 3)
m개

신경망의 정의

• 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델

- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 **수학적 함수** $F(\mathbf{x})$

$$\begin{aligned} F(\underbrace{\{v_i\}, \{\mathbf{w}_i\}, \{b_i\}}_{\substack{\uparrow \\ \text{N개의 원소로} \\ \text{이루어진 집합}}} : \mathbf{x}) &= \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i) \\ &\quad \text{N개 스칼라의 합} \\ &= v_1 \varphi(xw_1 + b_1) \\ &\quad + v_2 \varphi(xw_2 + b_2) \\ &\quad + v_3 \varphi(xw_3 + b_2) \\ &\quad + \dots \\ &\quad + v_N \varphi(xw_N + b_5) \end{aligned}$$

$$\begin{aligned} &\{v_1, v_2, \dots, v_N\} \\ &\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_N\} \\ &\text{N개} \end{aligned}$$

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델
- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 수학적 함수

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

“Universal Approximation Theorem”

입력값(x)에 적절한 상수와 벡터,
그리고 비선형 함수를 이용해 연산을 진행하면
어떠한 수학적 함수 F 를 함수 f 로 근사시킬 수 있다.
(단, $f : R^m$ 의 닫힌 유계 부분집합 $\rightarrow R$ 이며 φ 와 독립인 연속함수)

신경망의 정의

• 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델
- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 수학적 함수

"Universal Approximation Theorem"

Notation	Meaning
φ	Nonconstant, continuous, bounded, and monotonically increasing non-linear function
I_m	R^m 의 닫힌 유계 부분집합
$C(I_m)$	I_m 에서 \mathbb{R} 로 가는 연속함수의 집합
f	$C(I_m)$ 에 속하면서 φ 와 독립인 임의의 함수

위 표의 조건을 만족하는 φ 에 대해,

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\}; \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

와 같이 함수 F 를 정의하면, 역시 위 표의 조건을 만족하면서 정의된 임의의 함수 f 에 대해,

$$\forall \epsilon > 0, \exists \{v_i\}, \{\mathbf{w}_i\}, \{b_i\} \text{ s.t. } |F(\mathbf{x}) - f(\mathbf{x})| < \epsilon$$

신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 예시 1

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$

- 기존에 살펴본 수식과의 비교

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

5

1차원
스칼라

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 예시 1

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

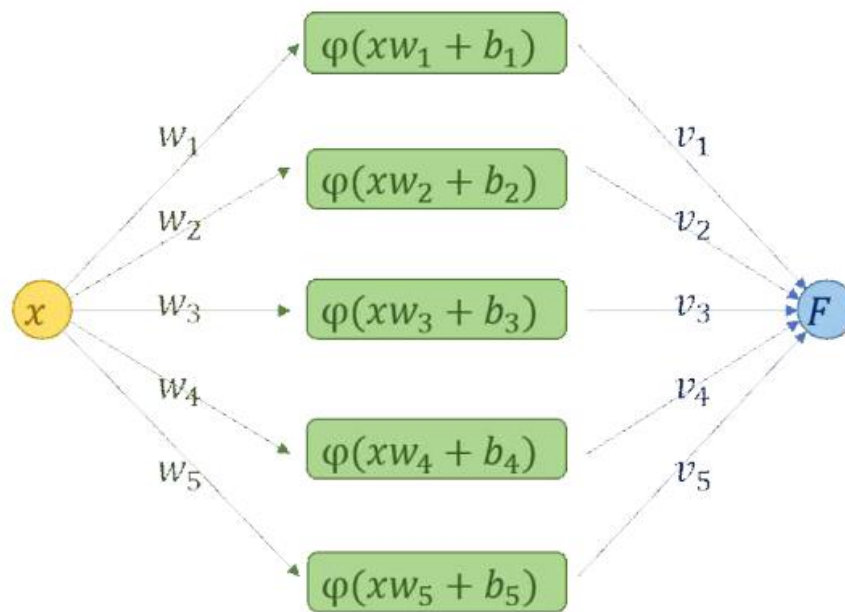
$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$

$$= v_1 \varphi(xw_1 + b_1)$$

$$+ v_2 \varphi(xw_2 + b_2)$$

+ ...

$$+ v_5 \varphi(xw_5 + b_5)$$



"방향 그래프"

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

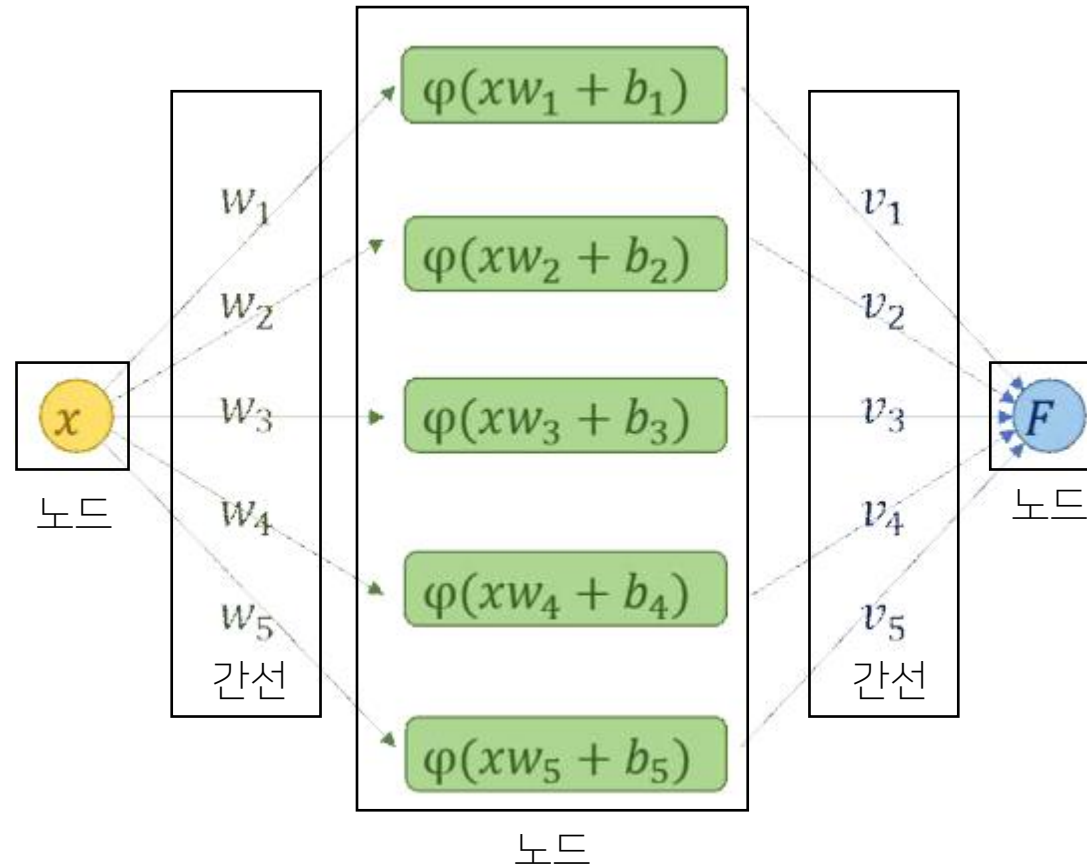
Hyper-
parameter

방향 그래프 : 각 간선에서 이동할 수 있는 방향이 정해져 있음

- 구성 요소

1) 노드

2) 간선



신경망의 정의

• 신경망의 구조

신경망의 학습

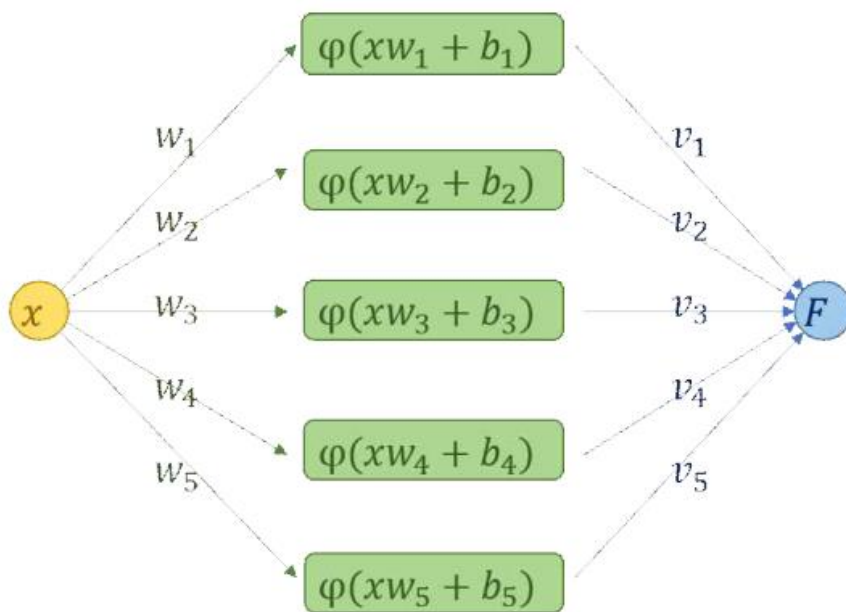
순전파와 역전파
반복

Hyper-
parameter

신경망의 예시 2

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$



Q) 그래프의 가중치와 편향은?

- 가중치 : w_i (입력값에 곱해주는 값)
- 편향 : b_i (함수 φ 에서 더해해주는 값)

Q) 편향을 가중치 처럼 보는 방법?

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

신경망의 예시 2

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

A) 편향을 가중치 처럼 보는 방법

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + \mathbf{1} \cdot b_i)$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

신경망의 예시 3

- 이변수함수 F , 벡터 \mathbf{x} (2차원), $N = 5$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^5 v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

$$\mathbf{x} = (x_1, x_2)^T, \mathbf{w} = (w_1, w_2)^T$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

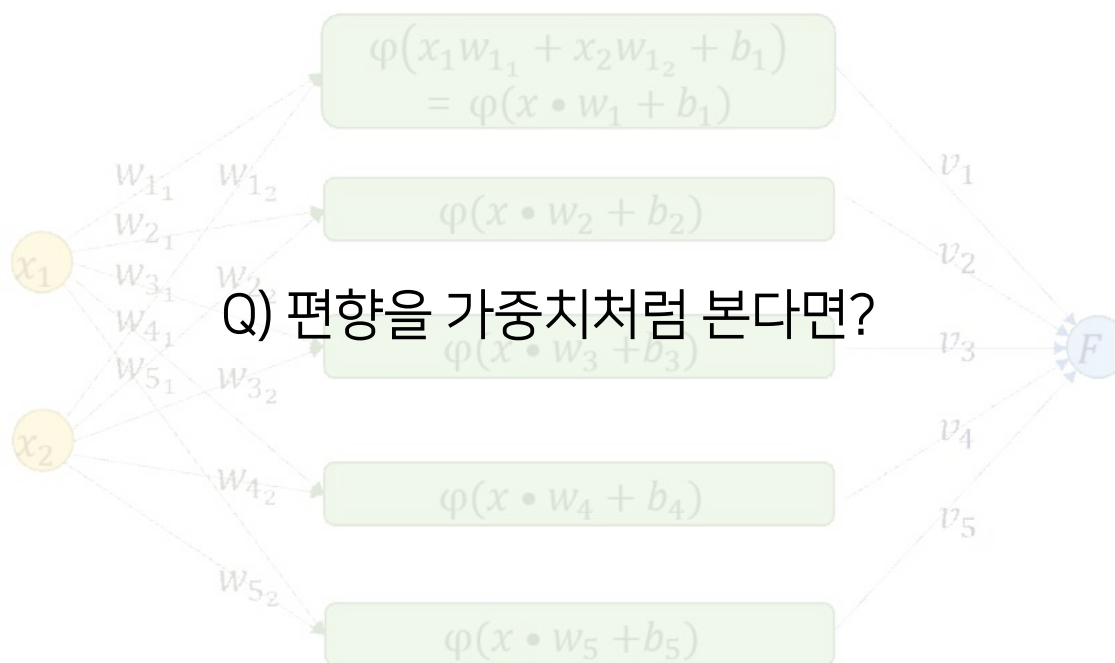
Hyper-
parameter

신경망의 예시 3

- 이변수함수 F , 벡터 \mathbf{x} (2차원), $N = 5$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^5 v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

$$\mathbf{x} = (x_1, x_2)^T, \mathbf{w} = (w_1, w_2)^T$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

신경망의 예시 4

- 이변수함수 F , 벡터 \mathbf{x} (2차원), $N = 5$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^5 v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + \mathbf{1} \cdot b_i)$$

$$\mathbf{x} = (x_1, x_2)^T, \mathbf{w} = (w_1, w_2)^T$$



3. 신경망의 구조 (2)

<머신러닝 첫 단추 끼우기>
4.2.절

신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

신경망의 구조

- 노드와 간선으로 이루어진, 방향 그래프
- 신경망 전체에 걸쳐 한 방향으로만 데이터가 전달됨
: 뉴런의 신호전달 기작과 유사한 양상
- 신경망 vs. 뉴런



신경망 (Neural Network, NN)



- 노드 : 수상돌기
- 간선 : 축삭돌기

뉴런 (Neuron)

노드 = 뉴런

신경망의 정의

- 신경망의 구조

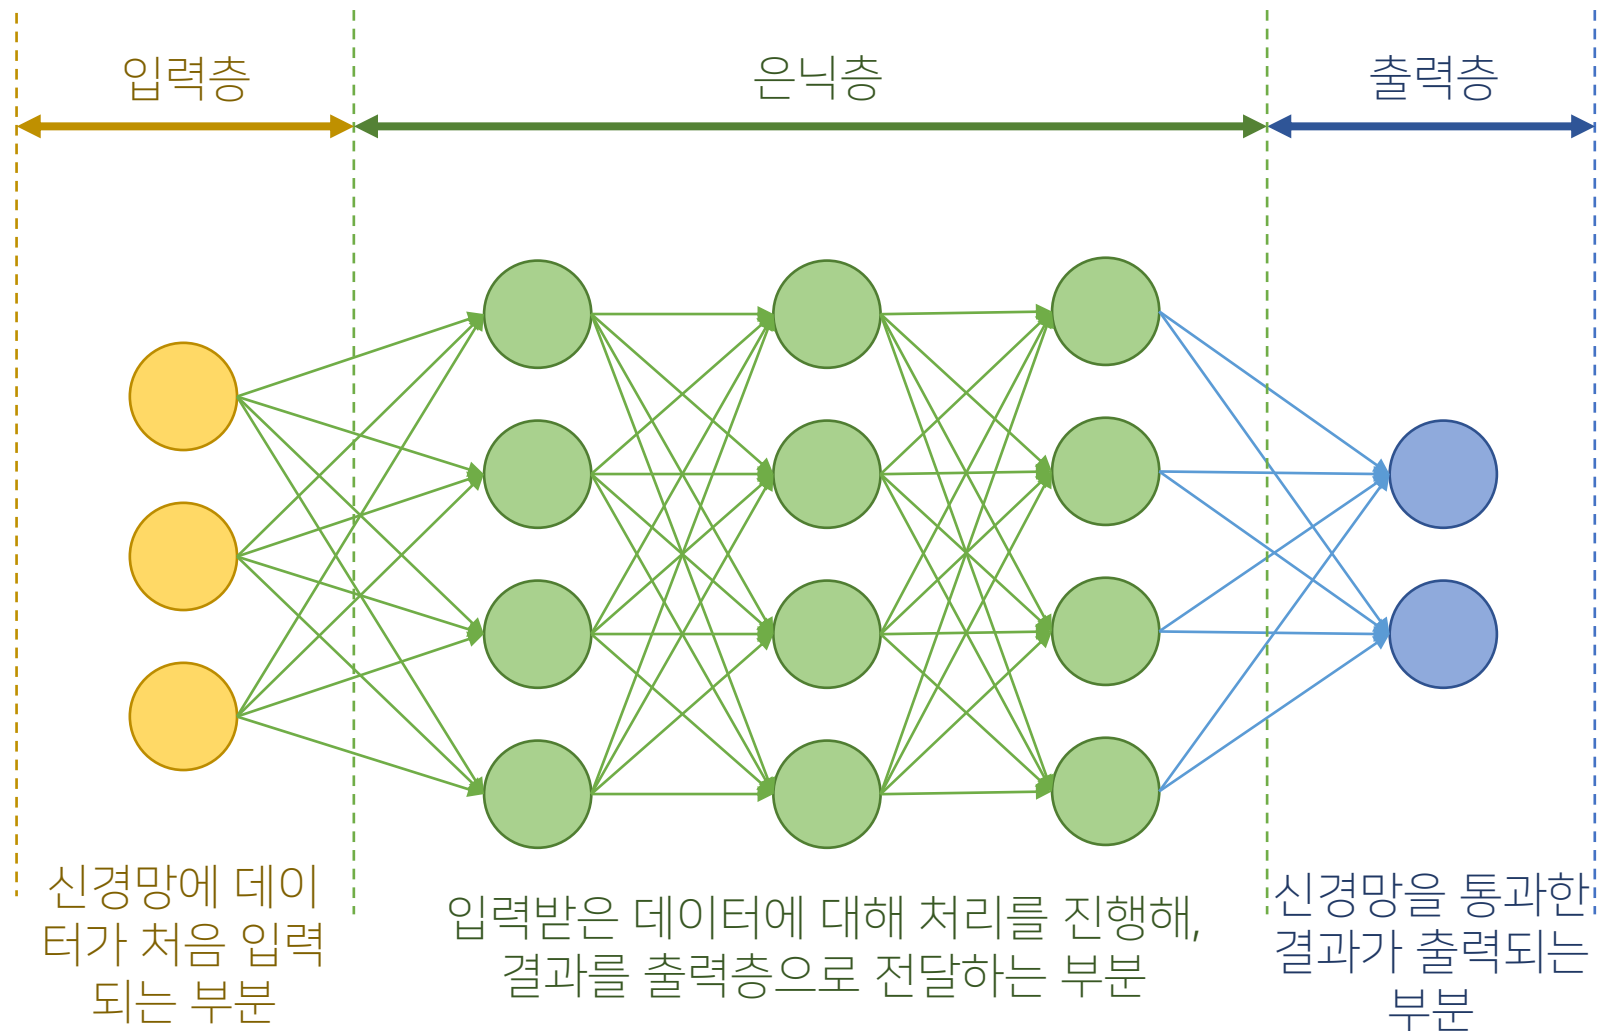
신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

계층 (Layer)

- 같은 선상에 있는 노드들의 집합



신경망의 정의

- **신경망의 구조**

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

심층 신경망

- 은닉층의 개수가 2개 이상인 신경망

딥러닝 (Deep Learning, DL)

- 심층 신경망에 대한 머신러닝
- 딥러닝 \subset 머신러닝
- 딥러닝과 머신러닝의 구체적인 차이 → <머신러닝 첫 단추 끼우기> 참고

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

각 뉴런의 역할 : 순전파

- 모든 뉴런 (= 노드) 이 공유하는 동일한 규칙

- 1) 각 뉴런에 입력되는 값은 여러 개 가능, 그러나 출력되는 값은 오직 하나
- 2) 각 뉴런에 입력되는 값에는 가중치가 곱해짐
- 3) 출력되는 값은 활성화 함수를 통과함

- **순전파** : 데이터가 입력층, 은닉층, 출력층을 차례로 통과해 출력값이 나오는 과정



신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

가중치 곱

- 밀집층 (Dense Layer) or 완전연결 계층 (Fully-Connected Layer)
: 모든 입력 데이터에 대해 가중치를 곱하는 뉴런들로 이루어진 계층
: 각 층의 노드들끼리 완전하게 연결된 신경망의 Layer



신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

가중치 곱

- 데이터가 2차원 이상인 경우?

벡터화 (Flatten, Vectorization) : n 차원 이상의 데이터를 1차원으로 만들어 주는 과정



신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

가중치 곱

- 데이터가 2차원 이상인 경우?

벡터화 (Flatten, Vectorization) : n 차원 이상의 데이터를 1차원으로 만들어 주는 과정



- 벡터화 과정의 문제점

: 데이터의 공간적인 정보가 무시됨

: 해결 → 합성곱 신경망 (CNN, Convolution Neural Network)

신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

활성화 함수 (Activation Function)

- 뉴런에서 최종적인 값을 내보내기 전에 통과 시켜주는 **비선형 함수**

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

1. 항등함수

- $\varphi(x) = x$
- 주로 출력층에서 사용
- 회귀 문제에서 많이 사용


2. Sigmoid

- $\varphi(x) = \frac{1}{1+e^{-x}}$
- 분류 문제에서 많이 사용

∴ 출력값이 0과 1사이의 값 → 해당 Class에 속할 확률로써 해석 가능!

Ex) 1에 가까울 경우 class A로 분류, 0에 가까울 경우 class B로 분류

- DL에서는 잘 활용되지 않음 : Gradient Vanishing



신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

3. ReLU

- $\varphi(x) = \max(x, 0)$
- Gradient Vanishing 문제 해결 가능
- 여전히 문제점을 가짐 → Leaky ReLU



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

- $0 < \varphi(x_k) < 1$

- $\sum_{i=1}^n \varphi(x_k) = 1$ \rightarrow

- 증가함수

분류 문제에서 각 class 에 속할 확률로 해석 가능
다중 클래스 분류 문제에 많이 사용됨

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x

1	2	1.5	0.6
---	---	-----	-----



y

$\frac{e^1}{e^1 + e^2 + e^{1.5} + e^{0.6}}$	$\frac{e^2}{e^1 + e^2 + e^{1.5} + e^{0.6}}$	$\frac{e^{1.5}}{e^1 + e^2 + e^{1.5} + e^{0.6}}$	$\frac{e^{0.6}}{e^1 + e^2 + e^{1.5} + e^{0.6}}$
---	---	---	---

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x

1	2	1.5	0.6
---	---	-----	-----



y

$\frac{2.72}{16.41}$	$\frac{7.39}{16.41}$	$\frac{4.48}{16.41}$	$\frac{1.82}{16.41}$
----------------------	----------------------	----------------------	----------------------

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x

1	2	1.5	0.6
---	---	-----	-----



y

0.166	0.450	0.273	0.111
-------	-------	-------	-------

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x			
1	2	1.5	0.6
↓			
y			
0.166	0.450	0.273	0.111

$$0.166 + 0.450 + 0.273 + 0.111 = 1$$

소프트맥스 함수의 값은 '확률' 로써 해석 가능!

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 필요성

1) 활성화 함수를 곱해주지 않는다면, 선형 모델밖에 표현하지 못함.

- 가중치를 곱해주는 과정은 선형 결합!

$$\mathbf{x} \cdot \mathbf{w}_i \rightarrow (\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j \rightarrow ((\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j) \cdot \mathbf{w}_k$$

- 비선형 함수를 추가해, 보다 일반적인 수학 모델 표현가능

- 정교한 규칙성 모델링 가능

2) 활성화 함수가 이용해야 신경망의 층 수를 증가시키는 것이 의미있음

- 선형 결합의 합성 = 선형 결합 \rightarrow 하나의 층을 사용하는 것과 같은 효과

- 활성화 함수를 사용할 경우, 층을 추가함에 따라 비선형성이 같이 추가됨

$$\mathbf{x} \cdot \mathbf{w}_i \rightarrow f(\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j \rightarrow f(f(\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j) \cdot \mathbf{w}_k$$

4. 신경망의 학습

<머신러닝 첫 단추 끼우기>
4.3.절

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

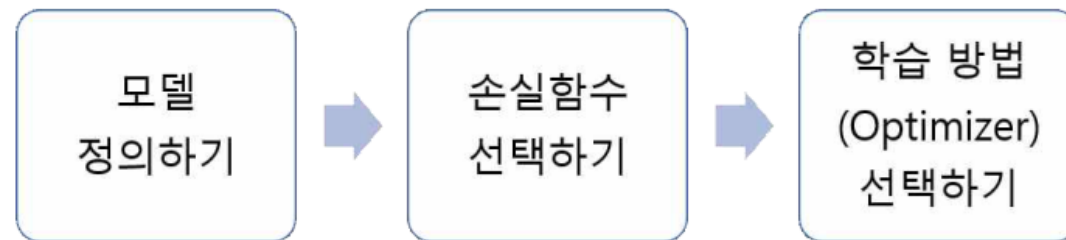
0. 데이터 전처리

1. 신경망 모델 구성

2. 손실함수 정의 및 계산

3. 손실함수 최적화 (학습)

- Backpropagation



신경망의 정의

신경망의 구조

- 신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

0. 데이터 전처리

1) 특성 스케일링 (Feature Scaling) or 정규화 (Normalization)

- Sample Data : Height and Weight

키 (m)	몸무게 (kg)	성별
180	83	남
170	73	남
175	78	남
170	64	여
163	52	여
154	45	여
165	70	남
160	55	여
173	71	남



키와 몸무게의 스케일이 매우 다름.

발생할 수 있는 문제점은?

신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

0. 데이터 전처리

1) 특성 스케일링 (Feature Scaling) or 정규화 (Normalization)

- ML/DL 모델은 '단위를 제외한 숫자' 만을 이용해 학습


→ 키 값의 중요도 증가

→ '몸무게' 에 대한 가중치 업데이트가 느리게 진행됨
(실습 4에서 확인해보실 수 있습니다)

$$\rightarrow \mathcal{L} = (\hat{y} - (wx + b))^2$$

0.1배 10배

- 데이터의 스케일을 맞춰 주는 과정이 필요



신경망의 정의

신경망의 구조

- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

0. 데이터 전처리

2-1) 해결방안 1 : 최소 - 최대 정규화

- 데이터의 최솟값 = 0 / 최댓값 = 1

$$x' = \frac{x - \min(Data)}{\max(Data) - \min(Data)}$$

- ex)

0	0	1	1	1	2	2	3	100
↓								
0	0	0.01	0.01	0.01	0.02	0.02	0.03	1

신경망의 정의

신경망의 구조

● **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

0. 데이터 전처리

2-2) 해결방안 2 : Z-점수 정규화

- 표준화 (Standardization)

$$Z = \frac{X - \mu}{\sigma}$$

- 데이터 값의 **평균을 0**으로 만들어, 대칭적인 분포로 변환
- 최대-최소 정규화에 비해 **Outlier**의 영향이 적음
(실습 4에서 확인해보실 수 있습니다)

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

1. 신경망 모델 구성

- 선형 회귀의 경우 : 수학적 함수 $F(x)$

$$F(m, b; x) = mx + b$$

- 학습을 진행시킬 모델 : 신경망 모델

Layer 수 / 각 Layer의 종류 / Activation Function

신경망이 $F(x)$ 의 값에 가까운 값을 도출하도록 학습시킬 예정

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

2. 손실함수 정의 및 계산

- 주어진 문제에 적합한 오차함수를 찾기 전에, 먼저 여러 오차함수에 대해 알아보자.

1) SSE (Sum of Squares for Error, 오차제곱합)

$$\mathcal{L}_{SSE} = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Q) 모델의 출력값이 [0.1, 0.7, 0.2]이고, 실제 값이 [0, 1, 0]일 때 SSE는?

$$(0 - 0.1)^2 + (1 - 0.7)^2 + (0 - 0.2)^2 = 0.01 + 0.49 + 0.04 = \mathbf{0.54}$$

2) MSE (Mean Squared Error, 평균 제곱 오차)

$$\mathcal{L}_{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 = \frac{\mathcal{L}_{SSE}}{n}$$

신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

2. 손실함수 정의 및 계산

- 주어진 문제에 적합한 오차함수를 찾기 전에, 먼저 여러 오차함수에 대해 알아보자.

3) |Residuals| (오차 절댓값의 합)

- N개의 데이터셋
- True data points : (x_i, \hat{y}_i) , $0 \leq i \leq N - 1$
- Expected data points : (x_i, y_i)
- 잔차(Residual) : $d_i = \hat{y}_i - y_i$

$$\mathcal{L}_{abs} = \sum_{i=1}^n |d_i|$$

4) CEE (Cross-Entropy Error, 교차 엔트로피 함수)

$$\mathcal{L}_{CEE} = - \sum_{i=1}^n y_i \log \hat{y}_i$$

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

2. 손실함수 정의 및 계산

- ex) 선형 회귀 문제에 적합한 오차함수는?

SSE (Sum of Squares for Error, 오차제곱합)

$$\mathcal{L}_{SSE} = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

3. 손실함수 최적화 (학습)

- 손실함수를 최적화 시키는 방법? **Optimizer**

Optimizer

- 경사하강법 (GD)를 기반으로 **손실함수를 최소화하는 모델 파라미터**를 찾는 알고리즘
- 기존 GD의 단점 보완 (Local minimum에 수렴하는 등의 문제)
- Adam, SGD

Gradient Descent (Recap)

$$\mathbf{w}_{new} = \mathbf{w}_{old} - \delta \cdot \nabla \mathcal{L}(\mathbf{w}) \Big|_{\mathbf{w}=\mathbf{w}_{old}}$$

- 편미분 계수 계산: **오차역전파법** (Backpropagation)

신경망의 정의


신경망의 구조

- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation



How to Calculate $\nabla \mathcal{L}(\mathbf{w}) \Big|_{\mathbf{w}=\mathbf{w}_{old}}$? Use **CHAIN RULE**

신경망의 정의

신경망의 구조

● **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Recap : Quiz 01

1. 다음 행렬곱 결과의 전치행렬을 구하여라.

$$\begin{pmatrix} 2 & 3 & 1 \\ -1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 5 \\ -2 \\ 3 \end{pmatrix}$$

- 결과 행렬의 Size : 2행 1열

☒ (7,0)

☐ (3,6)

☐ (0,7)

$$\begin{pmatrix} 2 \times 5 + 3 \times (-2) + 1 \times 3 \\ (-1) \times 5 + 2 \times (-2) + 3 \times 3 \end{pmatrix}$$

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Recap : Quiz 01

2. $f(x,y,z)=xy+yz$ 일 때, ∇f 는?

☒ $(y, x+z, y)$

☐ $(y, x+z, xy)$

☐ $(0, x, y)$

$$\begin{aligned}\nabla f &= \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right) \\ &= (y, x + z, y)\end{aligned}$$

신경망의 정의

신경망의 구조

● **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Recap : Quiz 01

3. $L(x, y) = xy, f(a, b) = (ab, a + b) = (x, y)$ 일 때, $\frac{\partial L}{\partial a}$ 를 구하시오.

Use **CHAIN RULE**

$$\frac{\partial L}{\partial a} = \frac{\partial L}{\partial x} \cdot \frac{\partial x}{\partial a} + \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial a}$$

$$= y \cdot b + x \cdot 1$$

$$= yb + x$$

신경망의 정의


신경망의 구조

- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation



$$w_{new} = w_{old} - \delta \cdot \nabla \mathcal{L}(w) \Big|_{w=w_{old}}$$

Loss Function $\mathcal{L}(w)$

신경망의 정의

신경망의 구조

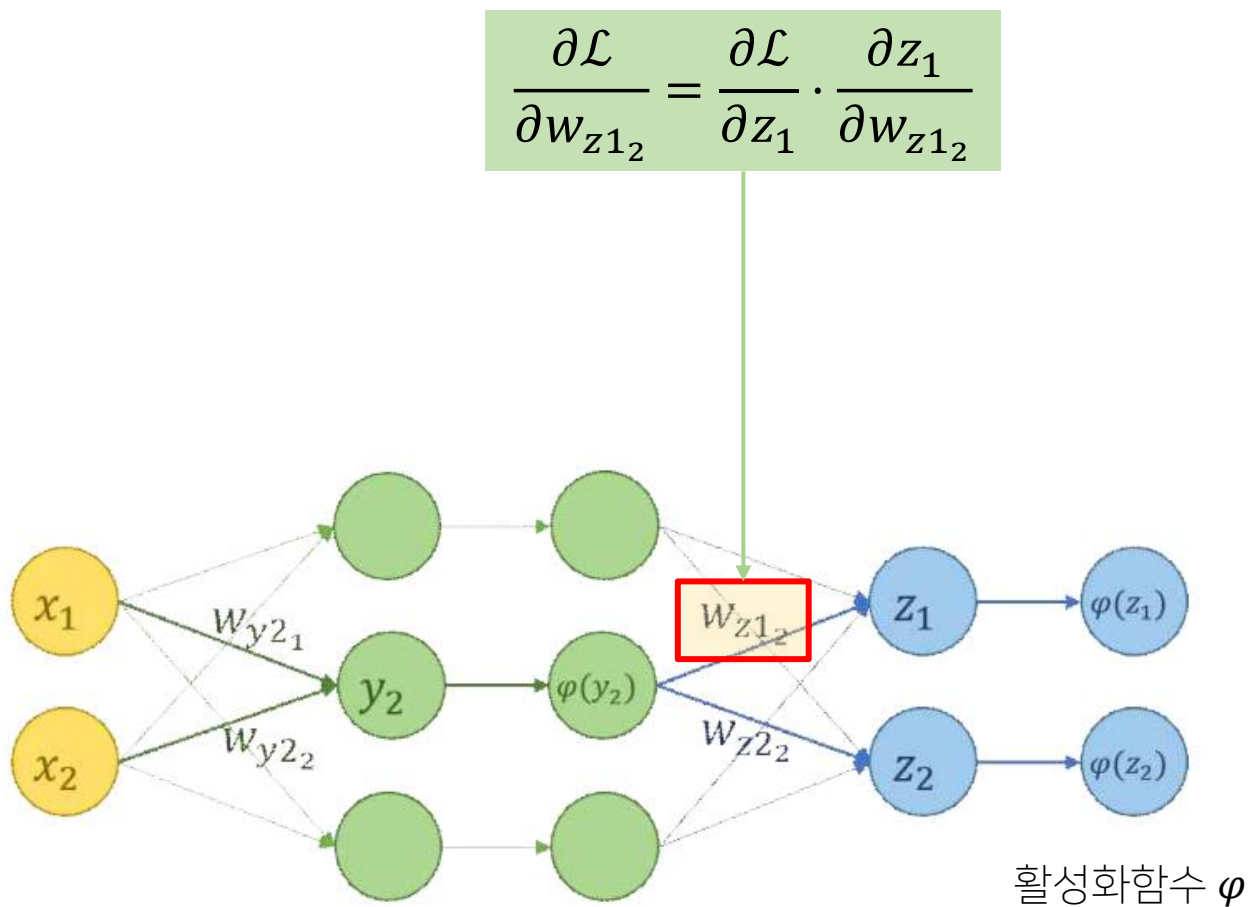
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{1} \mathbf{w}_{z1_2} : w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$$



신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{1} w_{z1_2} : w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$$



신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{1} w_{z1_2} : w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$$



신경망의 정의

신경망의 구조

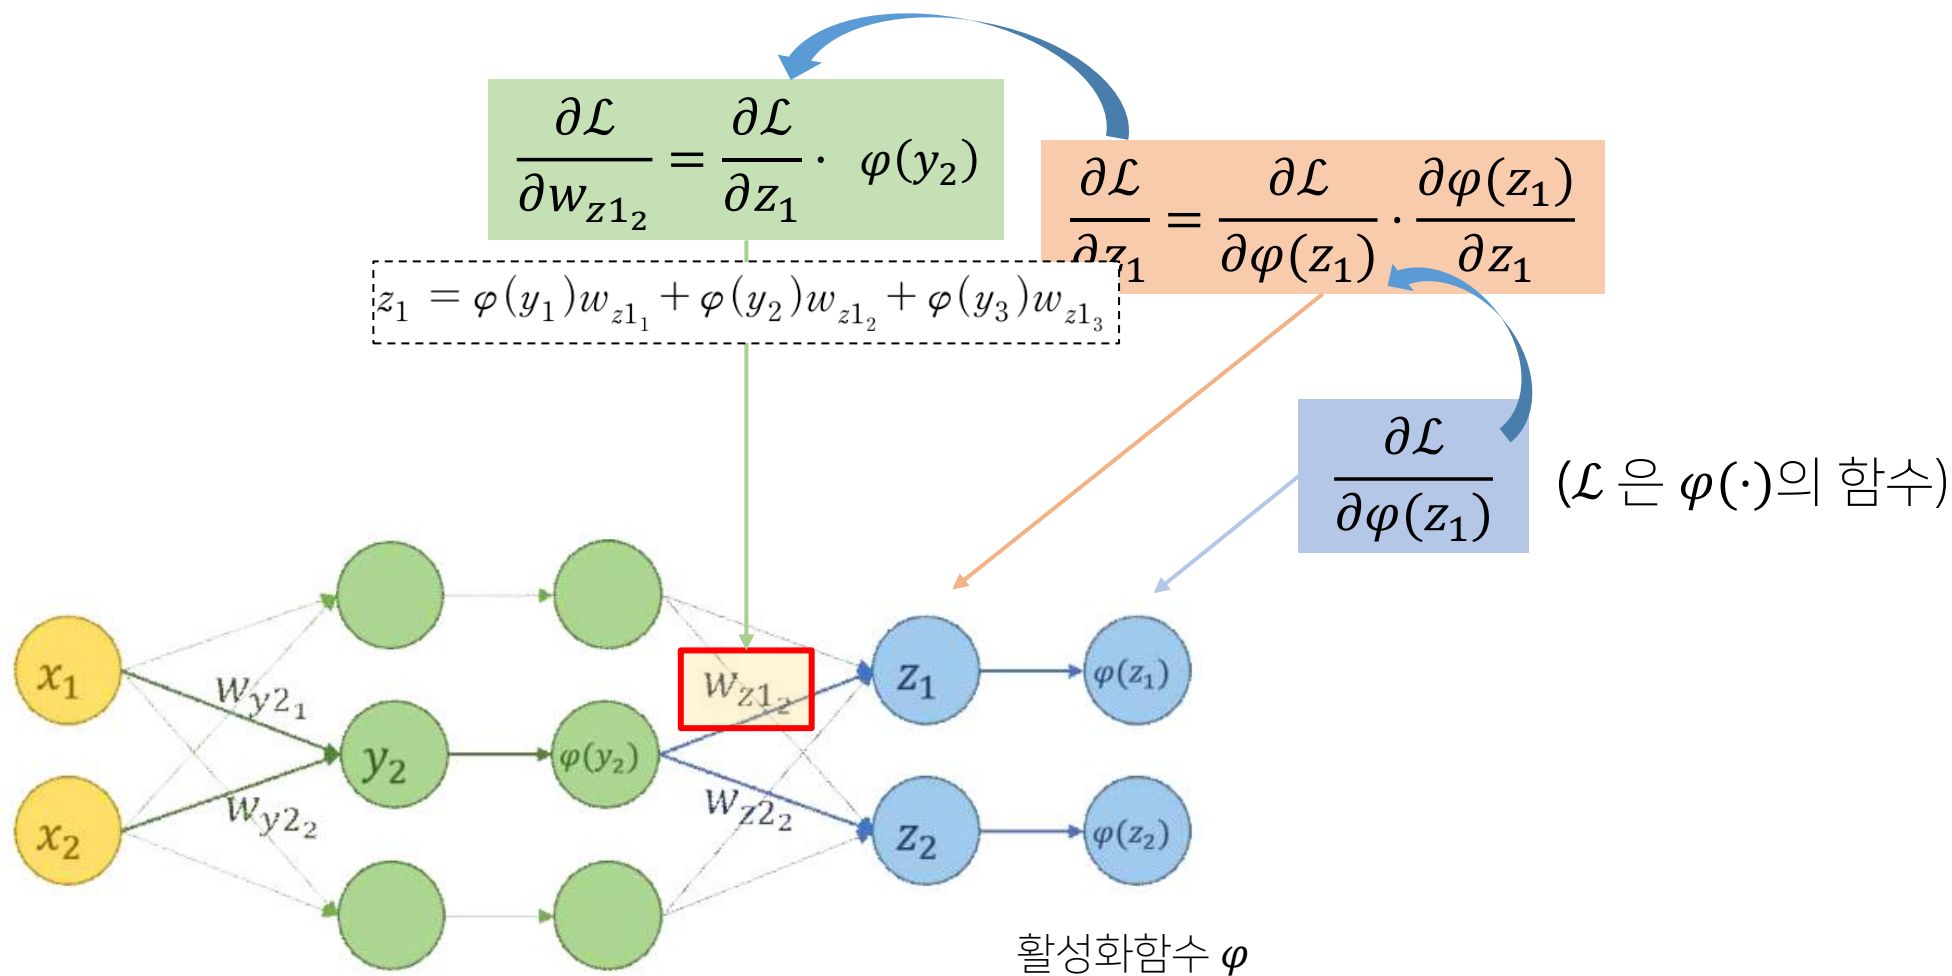
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

① w_{z1_2} : $w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$



신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

② w_{z2_2} : $w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$



$$\frac{\partial \mathcal{L}}{\partial w_{z2_2}} = \frac{\partial \mathcal{L}}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{z2_2}}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{2} \ w_{z2_2} : w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{z2_2}} = \frac{\partial \mathcal{L}}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{z2_2}}$$

$$\frac{\partial \mathcal{L}}{\partial z_2} = \frac{\partial \mathcal{L}}{\partial \varphi(z_2)} \cdot \frac{\partial \varphi(z_2)}{\partial z_2}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{2} \ w_{z2_2} : w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$$



신경망의 정의

신경망의 구조

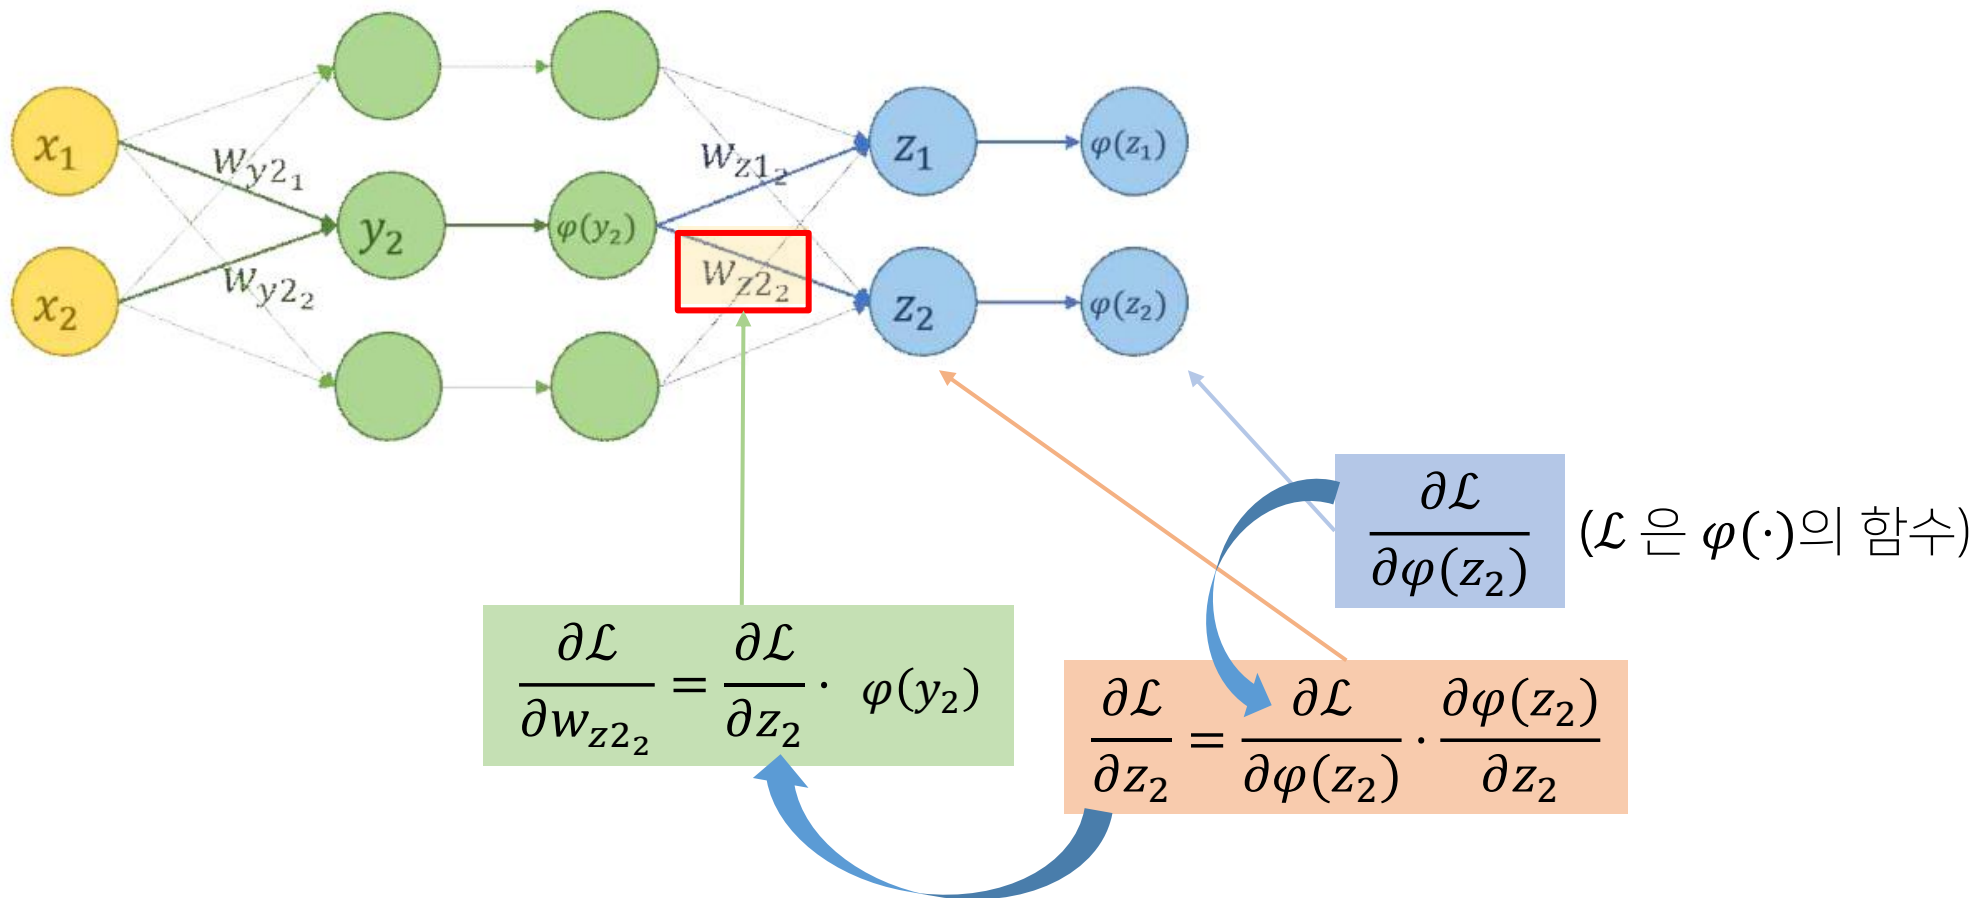
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{2} \ w_{z2_2} : w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$$



신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

③ w_{y2_2} : $w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot \frac{\partial y_2}{\partial w_{y2_2}}$$

신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

③ w_{y2_2} : $w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{3} \ w_{y2_2} : w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

$$\frac{\partial \mathcal{L}}{\partial y_2} = \frac{\partial \mathcal{L}}{\partial \varphi(y_2)} \cdot \frac{\partial \varphi(y_2)}{\partial y_2}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{3} \ w_{y2_2} : w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

$$\frac{\partial \mathcal{L}}{\partial \varphi(y_2)} = \frac{\partial \mathcal{L}}{\partial z_1} \cdot \frac{\partial z_1}{\partial \varphi(y_2)} + \frac{\partial \mathcal{L}}{\partial z_2} \cdot \frac{\partial z_2}{\partial \varphi(y_2)}$$

$$\frac{\partial \mathcal{L}}{\partial y_2} = \frac{\partial \mathcal{L}}{\partial \varphi(y_2)} \cdot \frac{\partial \varphi(y_2)}{\partial y_2}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{3} \ w_{y2_2} : w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

$$\frac{\partial \mathcal{L}}{\partial \varphi(y_2)} = \frac{\partial \mathcal{L}}{\partial z_1} \cdot w_{z1_2} + \frac{\partial \mathcal{L}}{\partial z_2} \cdot w_{z2_2}$$

$$\frac{\partial \mathcal{L}}{\partial y_2} = \frac{\partial \mathcal{L}}{\partial \varphi(y_2)} \cdot \frac{\partial \varphi(y_2)}{\partial y_2}$$

신경망의 정의

신경망의 구조

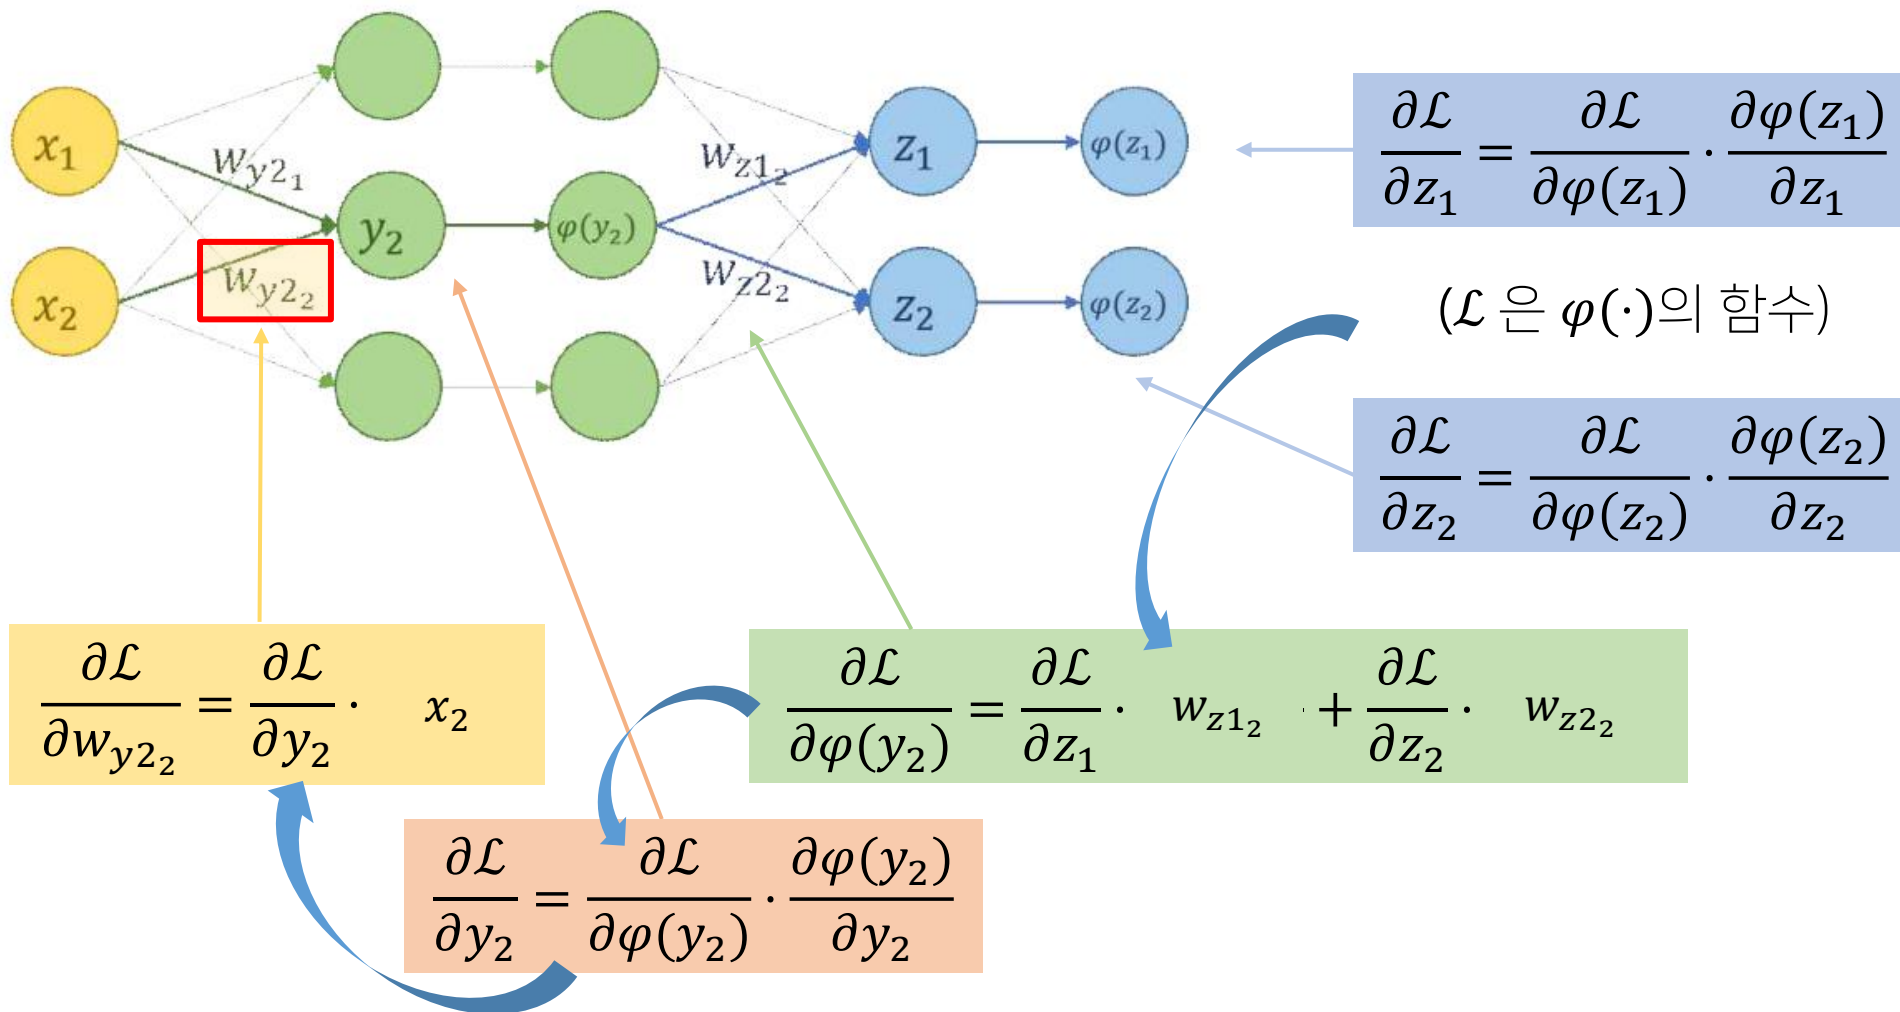
신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

③ w_{y2_2} : $w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$



신경망의 정의

신경망의 구조

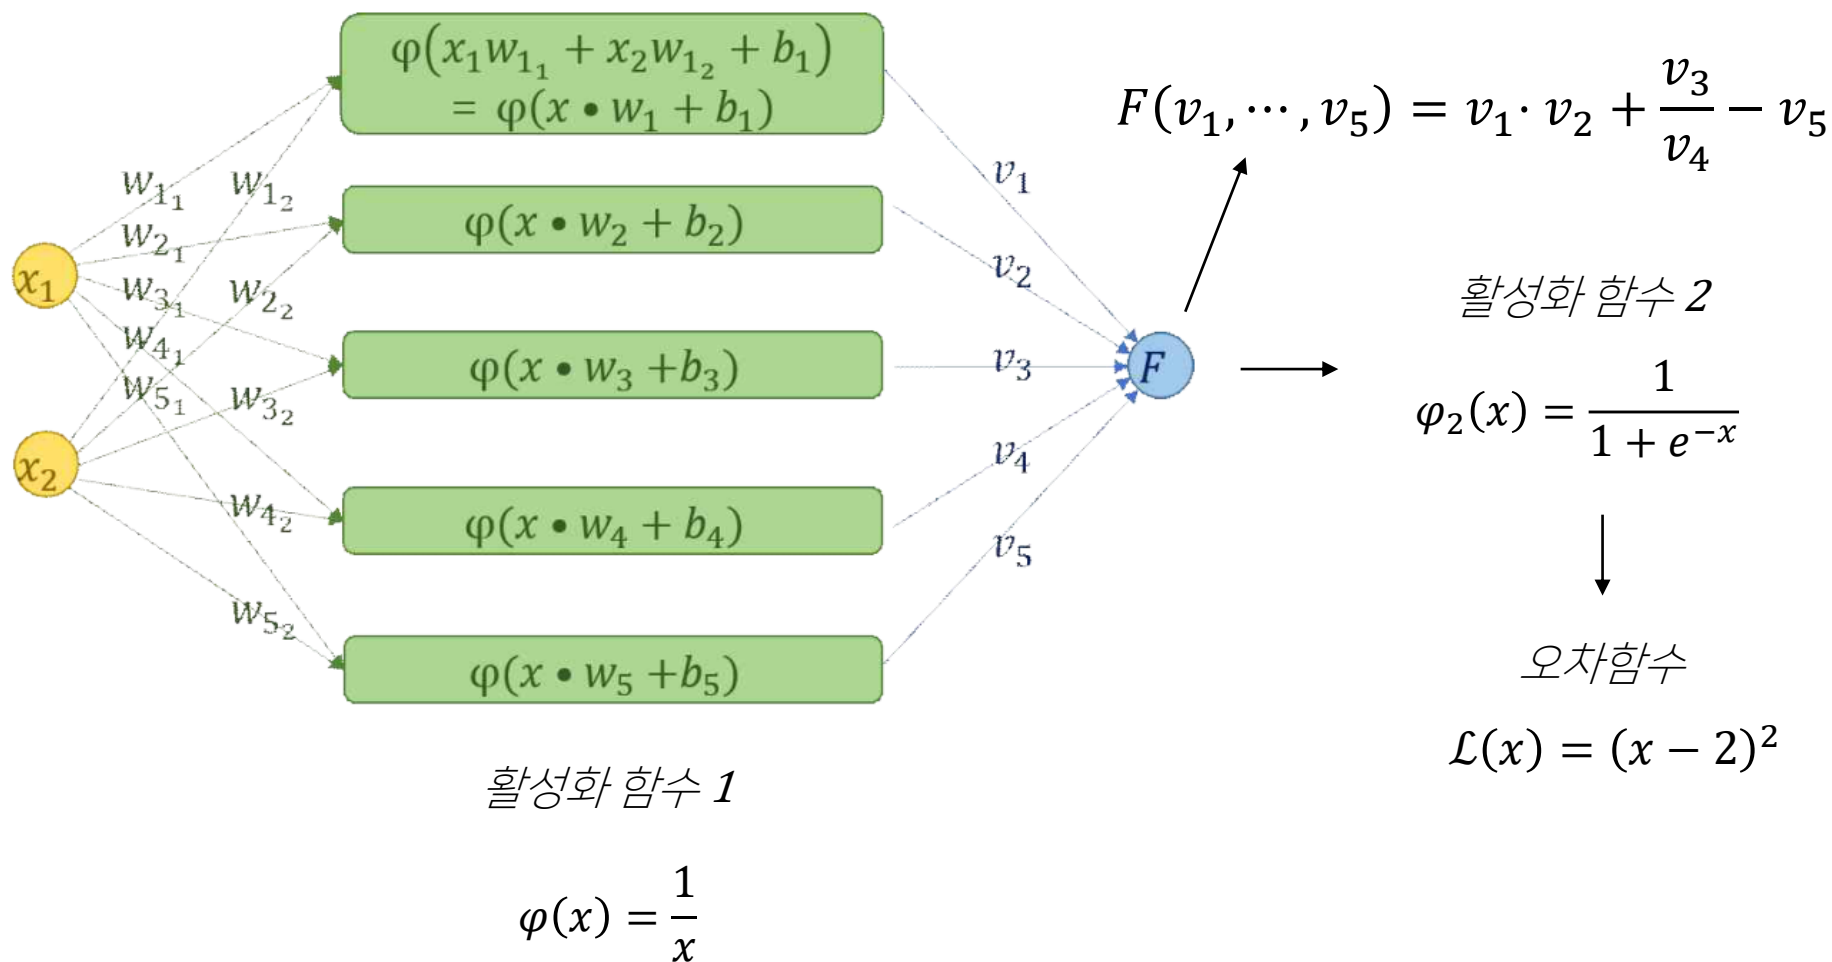
● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

활성화 함수 1: $\varphi(x) = \frac{1}{x}$

활성화 함수 2: $\varphi_2(x) = \frac{1}{1+e^{-x}}$

오차함수: $\mathcal{L}(x) = (x - 2)^2$

What is $\frac{\partial \mathcal{L}}{\partial w_{52}}$?

신경망의 정의

신경망의 구조


● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot \frac{\partial u}{\partial w_{5_2}}$$

신경망의 정의

신경망의 구조


● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

신경망의 정의

신경망의 구조

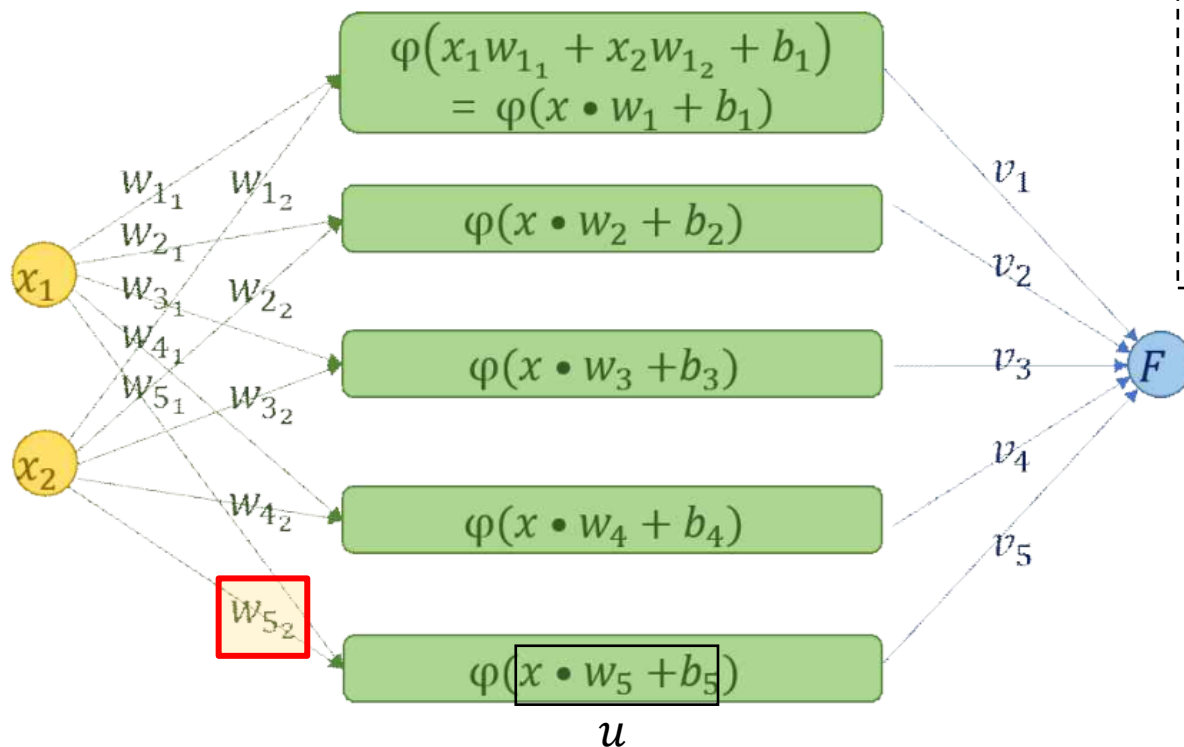
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \frac{\partial \varphi(u)}{\partial u}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1 : } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2 : } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수 : } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

신경망의 정의

신경망의 구조

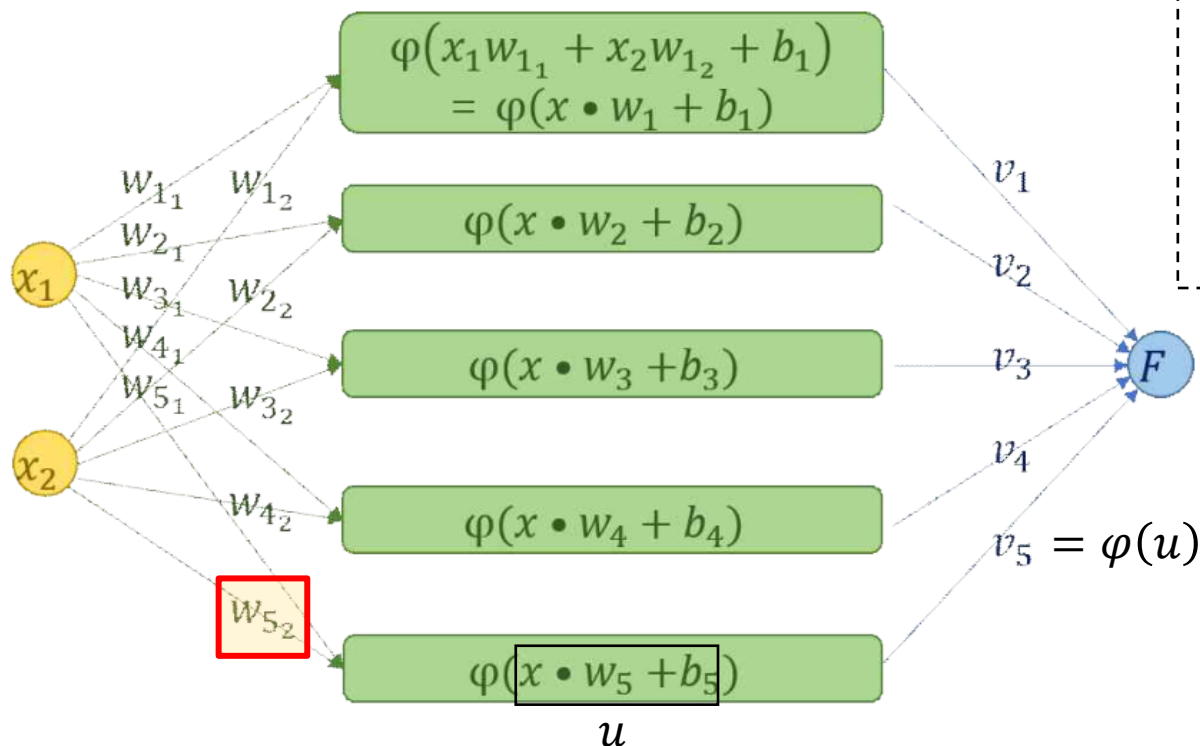
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot \frac{\partial F}{\partial \varphi(u)}$$

신경망의 정의

신경망의 구조

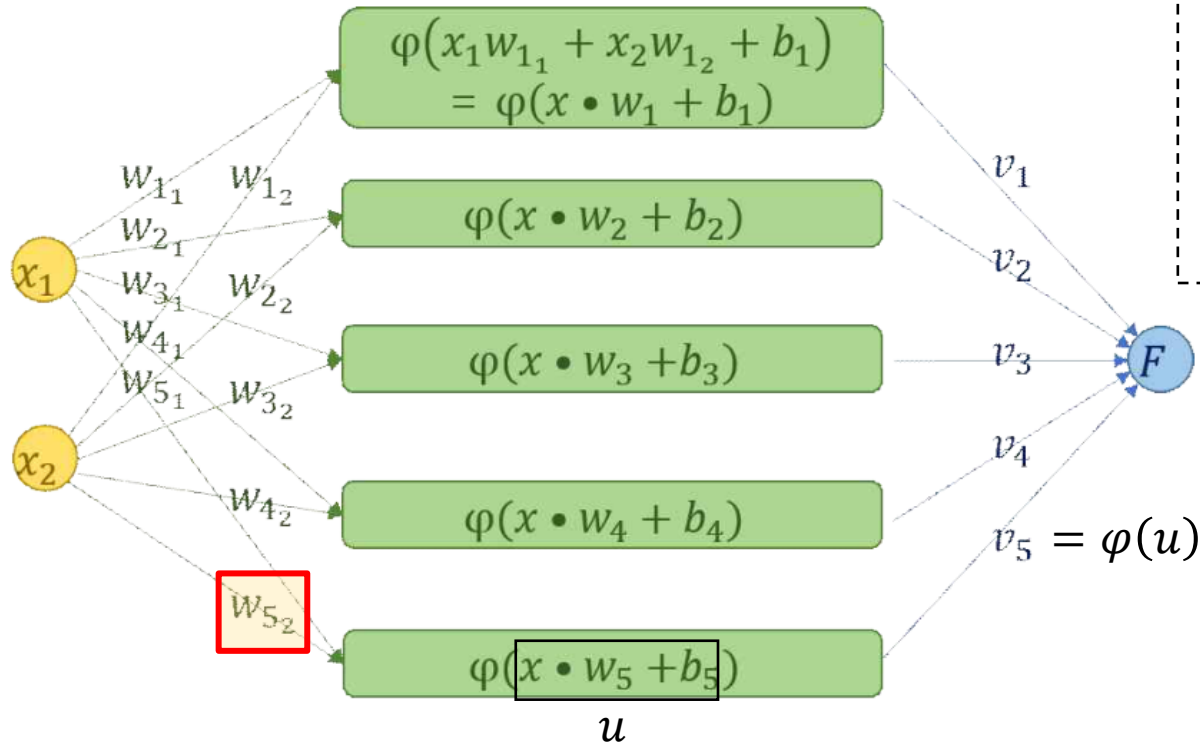
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

활성화 함수 1 : $\varphi(x) = \frac{1}{x}$

활성화 함수 2 : $\varphi_2(x) = \frac{1}{1+e^{-x}}$

오차함수 : $\mathcal{L}(x) = (x - 2)^2$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot \frac{\partial \varphi_2(F)}{\partial F}$$

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Sigmoid 함수 미분

$$\varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\frac{\partial \varphi_2(x)}{\partial x} = \frac{-e^{-x}}{(1+e^{-x})^2} = (1 - \varphi_2(x)) \cdot \varphi_2(x)$$

신경망의 정의

신경망의 구조

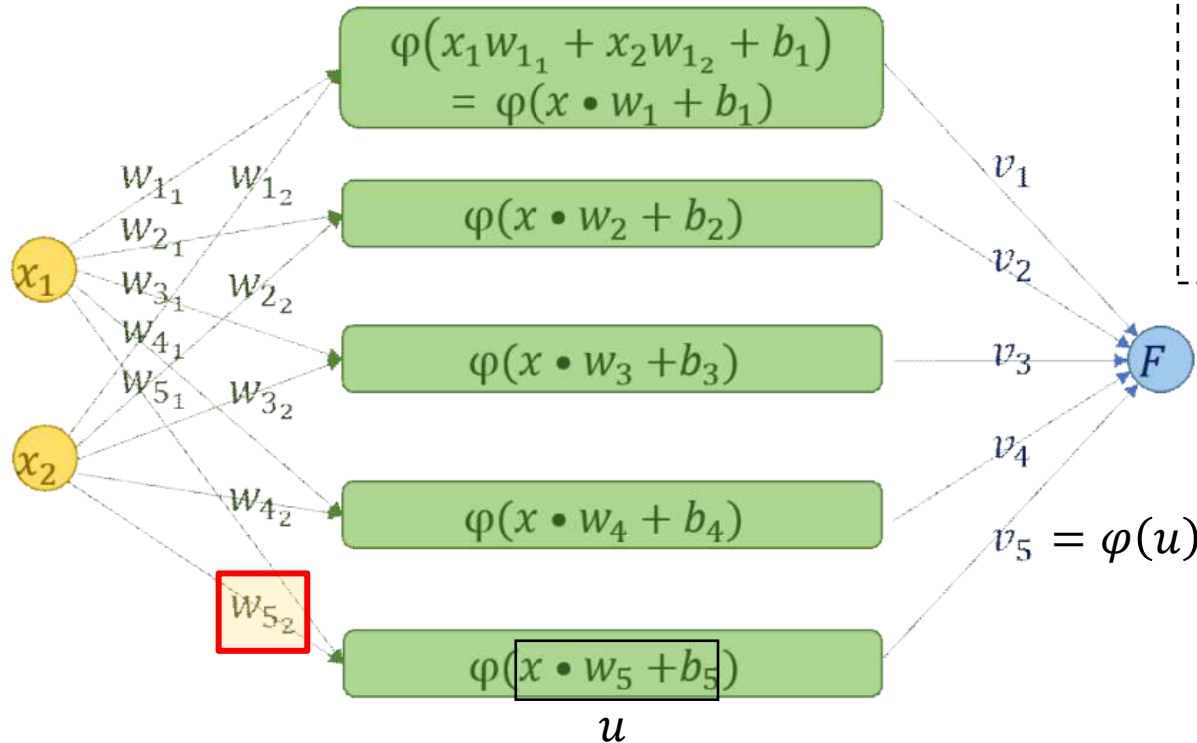
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

활성화 함수 1 : $\varphi(x) = \frac{1}{x}$

활성화 함수 2 : $\varphi_2(x) = \frac{1}{1+e^{-x}}$

오차함수 : $\mathcal{L}(x) = (x - 2)^2$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

$$\textcircled{6} \quad F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

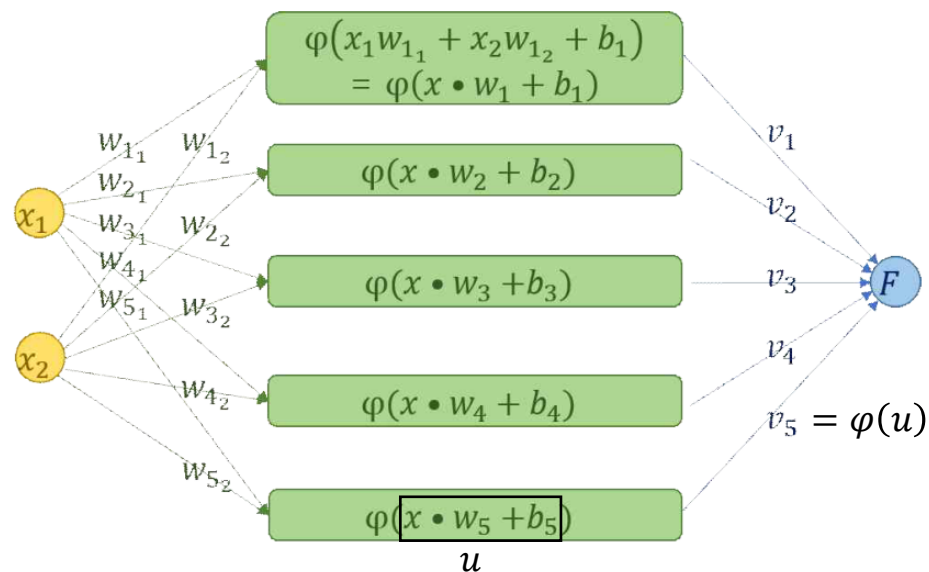
$$\textcircled{7} \quad \varphi(x) = \frac{1}{x}$$

$$\textcircled{8} \quad \varphi_2(x) = \frac{1}{1 + e^{-x}}$$

$$\textcircled{9} \quad \mathcal{L}(x) = (x - 2)^2$$

⑩

w_{1_1}	0.1	w_{2_1}	1.1
w_{1_2}	0.5	w_{2_2}	0.0
w_{1_3}	0.3	w_{2_3}	0.4
w_{1_4}	2.1	w_{2_4}	-0.1
w_{1_5}	-0.2	w_{2_5}	1.3
x_1	1.7	x_2	3.5



신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

$$\textcircled{6} \quad F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$


$$\textcircled{7} \quad \varphi(x) = \frac{1}{x}$$

$$\textcircled{8} \quad \varphi_2(x) = \frac{1}{1 + e^{-x}}$$

연산 순서:
(1) 순전파 진행
(2) 역전파 진행

⑩

w_{11}	0.1	w_{21}	1.1
w_{12}	0.5	w_{22}	0.0
w_{13}	0.3	w_{23}	0.4
w_{14}	2.1	w_{24}	-0.1
w_{15}	-0.2	w_{25}	1.3
x_1	1.7	x_2	3.5



신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

(1) 순전파 진행

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

$$\textcircled{6} \quad F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$


$$\textcircled{7} \quad \varphi(x) = \frac{1}{x}$$

$$\textcircled{8} \quad \varphi_2(x) = \frac{1}{1 + e^{-x}}$$

$$\textcircled{9} \quad \mathcal{L}(x) = (x - 2)^2$$

⑩

w_{1_1}	0.1	w_{2_1}	1.1
w_{1_2}	0.5	w_{2_2}	0.0
w_{1_3}	0.3	w_{2_3}	0.4
w_{1_4}	2.1	w_{2_4}	-0.1
w_{1_5}	-0.2	w_{2_5}	1.3
x_1	1.7	x_2	3.5



신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

① $\frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$

② $\frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$

③ $\frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$

④ $\frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$

⑤ $\frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$

⑥ $F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$

(2) 역전파 진행


⑦ $\varphi(x) = \frac{1}{x}$

⑧ $\varphi_2(x) = \frac{1}{1 + e^{-x}}$

⑨ $\mathcal{L}(x) = (x - 2)^2$

⑩

w_{1_1}	0.1	w_{2_1}	1.1
w_{1_2}	0.5	w_{2_2}	0.0
w_{1_3}	0.3	w_{2_3}	0.4
w_{1_4}	2.1	w_{2_4}	-0.1
w_{1_5}	-0.2	w_{2_5}	1.3
x_1	1.7	x_2	3.5



The background is a solid blue color with a white diagonal line running from the bottom left towards the top right. Various geometric shapes and lines are scattered across the blue area, including circles, squares, triangles, and lines in white, yellow, and pink. A white rounded rectangle is positioned in the center, containing the main title.

5. 순전파와 역전파의 반복

<머신러닝 첫 단추 끼우기>
4.4.절

신경망의 정의

신경망의 구조


신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

1 Iteration 의 정의

- 데이터 집합에 대해 순전파, 역전파를 통해 가중치 업데이트가 **1회** 일어나는 것



- 신경망에 1개의 Data씩 입력해줄 때 (Data 총 개수 : N개)
 - 전체 데이터에 대해 가중치 업데이트를 하기 위해 N iteration 필요
- 신경망에 모든 Data를 한 번에 입력할 때
 - 전체 데이터에 대해 가중치 업데이트를 하기 위해 1 iteration 필요

신경망의 정의

신경망의 구조

신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

실제 신경망에서는?

- N개의 전체 데이터를 M개씩 묶어 신경망에 입력

Batch (배치) / Batch Size

- Batch : 한 번에 신경망에 입력하는 데이터 묶음
- Batch Size : 1개의 Batch 내의 데이터 수 (= M)
- N개의 Data를 랜덤하게 섞고, M개씩 골라 Batch 생성



신경망의 정의

신경망의 구조

신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

Batch에서의 순전파와 역전파



- 순전파 : 각 batch를 이루는 데이터에 대해 독립적으로 진행
- 역전파 : 각 batch에서 계산된 손실함수의 평균을 이용해 진행
- More Details on ML LAB 5! (Next Seminar)

신경망의 정의


신경망의 구조

신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

1 epoch 의 정의



- 전체 데이터에 대해 순전파, 역전파를 통해 가중치 업데이트가 **1회** 일어나는 것

Q) 전체 데이터가 D 개, Batch Size가 M 일 때

- Batch 의 개수는? **D/M**
- 1 epoch 는 몇 iteration으로 이루어져 있는가? **D/M**

Batch 를 사용하는 이유?

In Next Seminar!

The background is a light blue gradient with a white diagonal line. Various geometric shapes and lines are scattered across the page, including circles, squares, triangles, and lines in different colors (white, yellow, pink, green).

6. Hyperparameter

<머신러닝 첫 단추 끼우기>
4.5.절

신경망의 정의

신경망의 구조

신경망의 학습

순전파와 역전파
반복

● Hyper-
parameter

What is Hyperparameter?

- 딥러닝 모델의 성능에 영향을 주는 변수
- 사용자가 직접 설정해 입력하며, 최적의 성능을 위해서는 Tuning 과정이 필요함
- “Parameter (가중치)를 효과적으로 업데이트 해 주기 위한 요소”

- Examples

- 가중치의 초기값
- Learning rate
- 학습의 종료조건
- Layer Depth
- Numbers of nodes in 1 Layer
- Activation Function
- Loss Function
- Optimizer
- batch size

7. Summary

Summary

- 수학적 모델을 신경망으로 근사할 수 있음
- 신경망 간선에 들어가는 가중치 및 편향의 적절한 값을 찾는 것이 해야할 일 (학습)
- 우선 파라미터 값을 적당히 초기화한 후, 순전파 결과를 도출하고 손실함수를 통해 그 결과가 얼마나 좋은지 평가
- “손실함수 값을 작게 하려면 파라미터 값을 어떻게 변화시킬까?” 에 대한 답을 주는 것이 경사하강법
- 가중치 및 편향에 대한 미분값을 구하는 역전파 과정에서 연쇄법칙을 사용