


2장 - (4). 신경망



멘토 이현수

1. 신경망의 정의

<머신러닝 첫 단추 끼우기>
4.1.절

- 신경망의 정의

신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 정의

- Neural Network (NN)
- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델
 - 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 수학적 함수
- 신경망을 사용할 경우, 충분한 관계가 표현 되는지 보장되는가?
 - Universal Approximation Thm. (교육자료 참고)

2. 신경망의 구조 (1)

<머신러닝 첫 단추 끼우기>
4.2.절

신경망의 정의

• 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를
하나의 함수 관계로 연결해 표현해주는 인공지능 모델

- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 **수학적 함수** $F(\mathbf{x})$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

비선형 함수

m차원
실벡터

(0, 1, 4, 5, ... 3)
m개

신경망의 정의

• 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델

- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 **수학적 함수** $F(\mathbf{x})$

$$\begin{aligned} F(\underbrace{\{v_i\}, \{\mathbf{w}_i\}, \{b_i\}}_{\substack{\uparrow \\ \text{N개의 원소로} \\ \text{이루어진 집합}}} : \mathbf{x}) &= \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i) \\ &\quad \text{N개 스칼라의 합} \\ &= v_1 \varphi(xw_1 + b_1) \\ &\quad + v_2 \varphi(xw_2 + b_2) \\ &\quad + v_3 \varphi(xw_3 + b_2) \\ &\quad + \dots \\ &\quad + v_N \varphi(xw_N + b_5) \end{aligned}$$

$$\begin{aligned} &\{v_1, v_2, \dots, v_N\} \\ &\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_N\} \\ &\text{N개} \end{aligned}$$

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델
- 모델 : 관찰한 데이터로부터 예측과 결정을 얻어내는 수학적 함수

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

“Universal Approximation Thm.”

입력값(x)에 적절한 상수와 벡터,
그리고 비선형 함수를 이용해 연산을 진행하면
어떠한 수학적 함수 F 가 f 로 근사시킬 수 있다.

신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 구조

- 입력(input) 데이터와 출력(output) 데이터 사이의 관계를 하나의 함수 관계로 연결해 표현해주는 인공지능 모델



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 예시 1

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$

- 기존에 살펴본 수식과의 비교

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^N v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

5

1차원
스칼라

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

신경망의 예시 1

- 일변수함수 F , 스칼라 x (1차원), $N = 5$


$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$

$$= v_1 \varphi(xw_1 + b_1)$$

$$+ v_2 \varphi(xw_2 + b_2)$$

+ ...

$$+ v_5 \varphi(xw_5 + b_5)$$



“방향 그래프”

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

방향 그래프 : 각 간선에서 이동할 수 있는 방향이 정해져 있음

- 구성 요소

1) 노드

2) 간선



신경망의 정의

• 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

신경망의 예시 2

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$



Q) 그래프의 가중치와 편향은?

- 가중치 : w_i (입력값에 곱해주는 값)
- 편향 : b_i (함수 φ 에서 더해해주는 값)

Q) 편향을 가중치 처럼 보는 방법?

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

신경망의 예시 2

- 일변수함수 F , 스칼라 x (1차원), $N = 5$

A) 편향을 가중치 처럼 보는 방법

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + \mathbf{1} \cdot b_i)$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

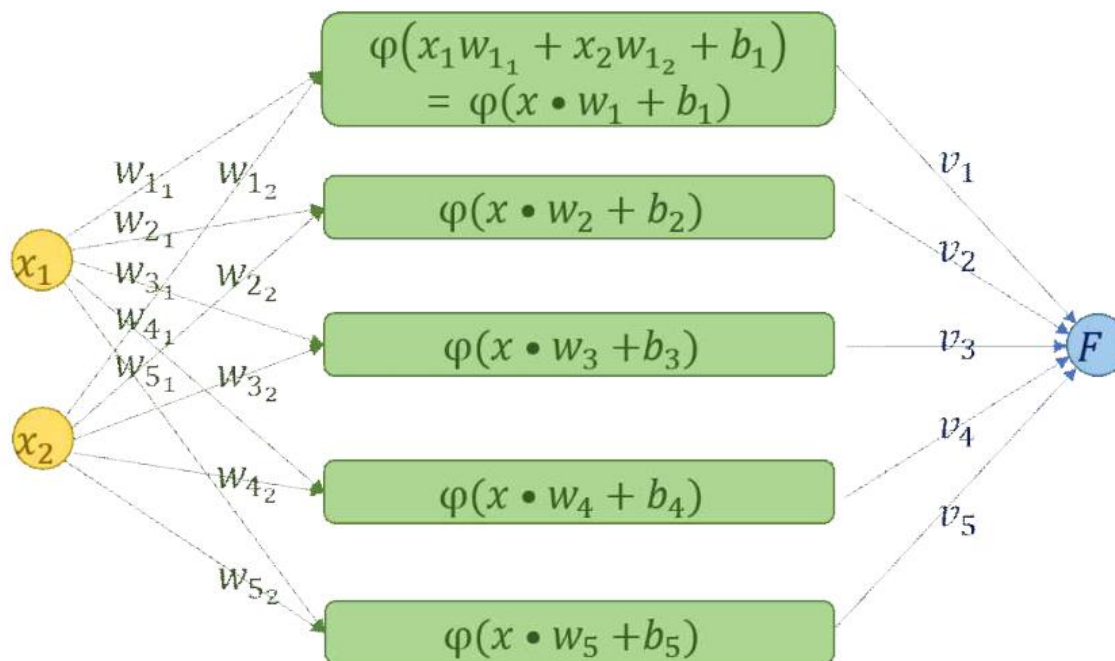
Hyper-
parameter

신경망의 예시 3

- 이변수함수 F , 벡터 \mathbf{x} (2차원), $N = 5$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^5 v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

$$\mathbf{x} = (x_1, x_2)^T, \mathbf{w} = (w_1, w_2)^T$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

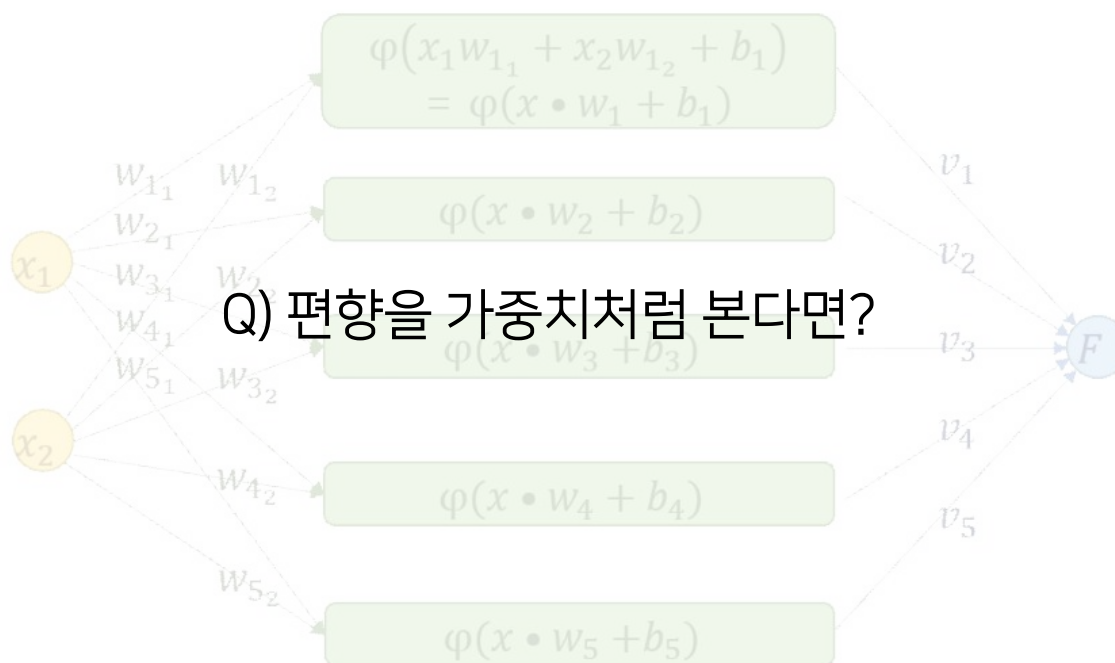
Hyper-
parameter

신경망의 예시 3

- 이변수함수 F , 벡터 \mathbf{x} (2차원), $N = 5$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^5 v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + b_i)$$

$$\mathbf{x} = (x_1, x_2)^T, \mathbf{w} = (w_1, w_2)^T$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

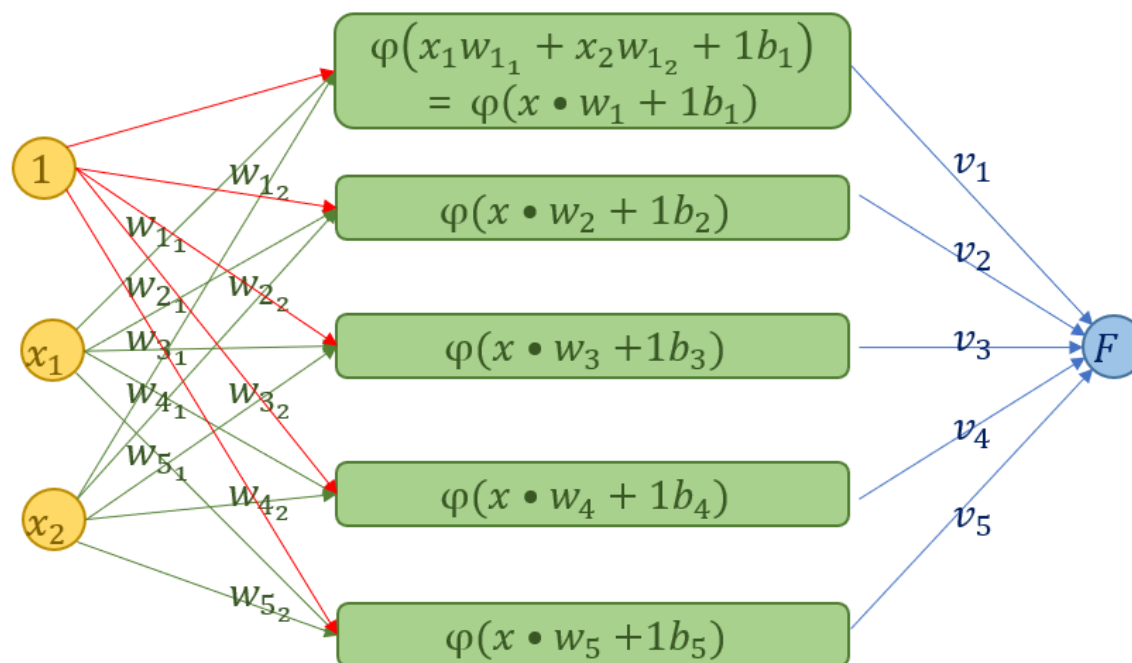
Hyper-
parameter

신경망의 예시 4

- 이변수함수 F , 벡터 \mathbf{x} (2차원), $N = 5$

$$F(\{v_i\}, \{\mathbf{w}_i\}, \{b_i\} : \mathbf{x}) = \sum_{i=1}^5 v_i \varphi(\mathbf{x} \cdot \mathbf{w}_i + \mathbf{1} \cdot b_i)$$

$$\mathbf{x} = (x_1, x_2)^T, \mathbf{w} = (w_1, w_2)^T$$



3. 신경망의 구조 (2)

<머신러닝 첫 단추 끼우기>
4.2.절

신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

신경망의 구조

- 노드와 간선으로 이루어진, 방향 그래프
- 신경망 전체에 걸쳐 한 방향으로만 데이터가 전달됨
: 뉴런의 신호전달 기작과 유사한 양상
- 신경망 vs. 뉴런



신경망 (Neural Network, NN)



- 노드 : 수상돌기
- 간선 : 축삭돌기

뉴런 (Neuron)

노드 = 뉴런

신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

계층 (Layer)

- 같은 선상에 있는 노드들의 집합



신경망의 정의

- **신경망의 구조**

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

심층 신경망

- 은닉층의 개수가 2개 이상인 신경망

딥러닝 (Deep Learning, DL)

- 심층 신경망에 대한 머신러닝
- 딥러닝 \subset 머신러닝
- 딥러닝과 머신러닝의 구체적인 차이 → <머신러닝 첫 단추 끼우기> 참고

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

각 뉴런의 역할 : 순전파

- 모든 뉴런 (= 노드) 이 공유하는 동일한 규칙

- 1) 각 뉴런에 입력되는 값은 여러 개 가능, 그러나 출력되는 값은 오직 하나
- 2) 각 뉴런에 입력되는 값에는 가중치가 곱해짐
- 3) 출력되는 값은 활성화 함수를 통과함

- **순전파** : 데이터가 입력층, 은닉층, 출력층을 차례로 통과해 출력값이 나오는 과정



신경망의 정의

- 신경망의 구조


신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

가중치 곱

- 밀집층 (Dense Layer) or 완전연결 계층 (Fully-Connected Layer)
 - : 모든 입력 데이터에 대해 가중치를 곱하는 뉴런들로 이루어진 계층
 - : 각 층의 노드들끼리 완전하게 연결된 신경망의 Layer



신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

가중치 곱

- 데이터가 2차원 이상인 경우?

벡터화 (Flatten, Vectorization) : n 차원 이상의 데이터를 1차원으로 만들어 주는 과정



신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

가중치 곱

- 데이터가 2차원 이상인 경우?

벡터화 (Flatten, Vectorization) : n 차원 이상의 데이터를 1차원으로 만들어 주는 과정



- 벡터화 과정의 문제점

: 데이터의 공간적인 정보가 무시됨

: 해결 → 합성곱 신경망 (CNN, Convolution Neural Network)

신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

활성화 함수 (Activation Function)

- 뉴런에서 최종적인 값을 내보내기 전에 통과 시켜주는 **비선형 함수**

$$F(\{v_i\}, \{w_i\}, \{b_i\} : x) = \sum_{i=1}^5 v_i \varphi(x \cdot w_i + b_i)$$



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

1. 항등함수

- $\varphi(x) = x$
- 주로 출력층에서 사용
- 회귀 문제에서 많이 사용


2. Sigmoid

- $\varphi(x) = \frac{1}{1+e^{-x}}$
- 분류 문제에서 많이 사용

∴ 출력값이 0과 1사이의 값 → 해당 Class에 속할 확률로써 해석 가능!

Ex) 1에 가까울 경우 class A로 분류, 0에 가까울 경우 class B로 분류

- DL에서는 잘 활용되지 않음 : Gradient Vanishing



신경망의 정의

- 신경망의 구조

신경망의 학습


순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

3. ReLU

- $\varphi(x) = \max(x, 0)$
- Gradient Vanishing 문제 해결 가능
- 여전히 문제점을 가짐 → Leaky ReLU



신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

- $0 < \varphi(x_k) < 1$

- $\sum_{i=1}^n \varphi(x_k) = 1$ \rightarrow

- 증가함수

분류 문제에서 각 class 에 속할 확률로 해석 가능
다중 클래스 분류 문제에 많이 사용됨

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x

1	2	1.5	0.6
---	---	-----	-----



y

$\frac{e^1}{e^1 + e^2 + e^{1.5} + e^{0.6}}$	$\frac{e^2}{e^1 + e^2 + e^{1.5} + e^{0.6}}$	$\frac{e^{1.5}}{e^1 + e^2 + e^{1.5} + e^{0.6}}$	$\frac{e^{0.6}}{e^1 + e^2 + e^{1.5} + e^{0.6}}$
---	---	---	---

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x

1	2	1.5	0.6
---	---	-----	-----



y

$\frac{2.72}{16.41}$	$\frac{7.39}{16.41}$	$\frac{4.48}{16.41}$	$\frac{1.82}{16.41}$
----------------------	----------------------	----------------------	----------------------

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x

1	2	1.5	0.6
---	---	-----	-----



y

0.166	0.450	0.273	0.111
-------	-------	-------	-------

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 종류

4. Softmax

- 입력값이 x_1, x_2, \dots, x_n , 출력값이 y_1, y_2, \dots, y_n 일 때

$$y_k = \text{softmax}(x_k) = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$$

x			
1	2	1.5	0.6
y			
0.166	0.450	0.273	0.111

$$0.166 + 0.450 + 0.273 + 0.111 = 1$$

소프트맥스 함수의 값은 '확률' 로써 해석 가능!

신경망의 정의

- 신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

활성화 함수의 필요성

1) 활성화 함수를 곱해주지 않는다면, 선형 모델밖에 표현하지 못함.

- 가중치를 곱해주는 과정은 선형 결합!

$$\mathbf{x} \cdot \mathbf{w}_i \rightarrow (\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j \rightarrow ((\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j) \cdot \mathbf{w}_k$$

- 비선형 함수를 추가해, 보다 일반적인 수학 모델 표현가능

- 정교한 규칙성 모델링 가능

2) 활성화 함수가 이용해야 신경망의 층 수를 증가시키는 것이 의미있음

- 선형 결합의 합성 = 선형 결합 \rightarrow 하나의 층을 사용하는 것과 같은 효과

- 활성화 함수를 사용할 경우, 층을 추가함에 따라 비선형성이 같이 추가됨

$$\mathbf{x} \cdot \mathbf{w}_i \rightarrow f(\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j \rightarrow f(f(\mathbf{x} \cdot \mathbf{w}_i) \cdot \mathbf{w}_j) \cdot \mathbf{w}_k$$

4. 신경망의 학습

<머신러닝 첫 단추 끼우기>
4.3.절

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

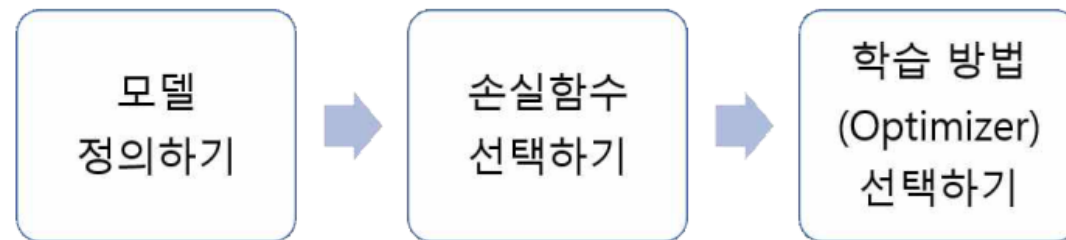
0. 데이터 전처리

1. 신경망 모델 구성

2. 손실함수 정의 및 계산

3. 손실함수 최적화 (학습)

- Backpropagation



신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복


Hyper-
parameter

0. 데이터 전처리

1) 특성 스케일링 (Feature Scaling) or 정규화 (Normalization)

- Sample Data : Height and Weight

키 (m)	몸무게 (kg)	성별
180	83	남
170	73	남
175	78	남
170	64	여
163	52	여
154	45	여
165	70	남
160	55	여
173	71	남



키와 몸무게의 스케일이 매우 다름.

발생할 수 있는 문제점은?

신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

0. 데이터 전처리

1) 특성 스케일링 (Feature Scaling) or 정규화 (Normalization)

- ML/DL 모델은 '단위를 제외한 숫자' 만을 이용해 학습


→ 키 값의 중요도 증가

→ '몸무게' 에 대한 가중치 업데이트가 느리게 진행됨
(실습 4에서 확인해보실 수 있습니다)

$$\rightarrow \mathcal{L} = (\hat{y} - (wx + b))^2$$

0.1배 10배

- 데이터의 스케일을 맞춰 주는 과정이 필요



신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

0. 데이터 전처리

2-1) 해결방안 1 : 최소 - 최대 정규화

- 데이터의 최솟값 = 0 / 최댓값 = 1

$$x' = \frac{x - \min(Data)}{\max(Data) - \min(Data)}$$

- ex)

0	0	1	1	1	2	2	3	100
↓								
0	0	0.01	0.01	0.01	0.02	0.02	0.03	1

신경망의 정의

신경망의 구조

● **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

0. 데이터 전처리

2-2) 해결방안 2 : Z-점수 정규화

- 표준화 (Standardization)

$$Z = \frac{X - \mu}{\sigma}$$

- 데이터 값의 **평균을 0**으로 만들어, 대칭적인 분포로 변환
- 최대-최소 정규화에 비해 **Outlier**의 영향이 적음
(실습 4에서 확인해보실 수 있습니다)

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

1. 신경망 모델 구성

- 선형 회귀의 경우 : 수학적 함수 $F(x)$

$$F(m, b; x) = mx + b$$

- 학습을 진행시킬 모델 : 신경망 모델

Layer 수 / 각 Layer의 종류 / Activation Function

신경망이 $F(x)$ 의 값에 가까운 값을 도출하도록 학습시킬 예정

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

2. 손실함수 정의 및 계산

- 주어진 문제에 적합한 오차함수를 찾기 전에, 먼저 여러 오차함수에 대해 알아보자.

1) SSE (Sum of Squares for Error, 오차제곱합)

$$\mathcal{L}_{SSE} = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Q) 모델의 출력값이 [0.1, 0.7, 0.2]이고, 실제 값이 [0, 1, 0]일 때 SSE는?

$$(0 - 0.1)^2 + (1 - 0.7)^2 + (0 - 0.2)^2 = 0.01 + 0.49 + 0.04 = \mathbf{0.54}$$

2) MSE (Mean Squared Error, 평균 제곱 오차)

$$\mathcal{L}_{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 = \frac{\mathcal{L}_{SSE}}{n}$$

신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

2. 손실함수 정의 및 계산

- 주어진 문제에 적합한 오차함수를 찾기 전에, 먼저 여러 오차함수에 대해 알아보자.

3) |Residuals| (오차 절댓값의 합)

- N개의 데이터셋
- True data points : (x_i, \hat{y}_i) , $0 \leq i \leq N - 1$
- Expected data points : (x_i, y_i)
- 잔차(Residual) : $d_i = \hat{y}_i - y_i$

$$\mathcal{L}_{abs} = \sum_{i=1}^n |d_i|$$

4) CEE (Cross-Entropy Error, 교차 엔트로피 함수)

$$\mathcal{L}_{CEE} = - \sum_{i=1}^n y_i \log \hat{y}_i$$

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

2. 손실함수 정의 및 계산

- ex) 선형 회귀 문제에 적합한 오차함수는?

SSE (Sum of Squares for Error, 오차제곱합)

$$\mathcal{L}_{SSE} = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

신경망의 정의

신경망의 구조

● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

3. 손실함수 최적화 (학습)

- 손실함수를 최적화 시키는 방법? **Optimizer**

Optimizer

- 경사하강법 (GD)를 기반으로 **손실함수를 최소화하는 모델 파라미터**를 찾는 알고리즘
- 기존 GD의 단점 보완 (Local minimum에 수렴하는 등의 문제)
- Adam, SGD

Gradient Descent (Recap)

$$\mathbf{w}_{new} = \mathbf{w}_{old} - \delta \cdot \nabla \mathcal{L}(\mathbf{w}) \Big|_{\mathbf{w}=\mathbf{w}_{old}}$$

- 편미분 계수 계산: **오차역전파법** (Backpropagation)

신경망의 정의

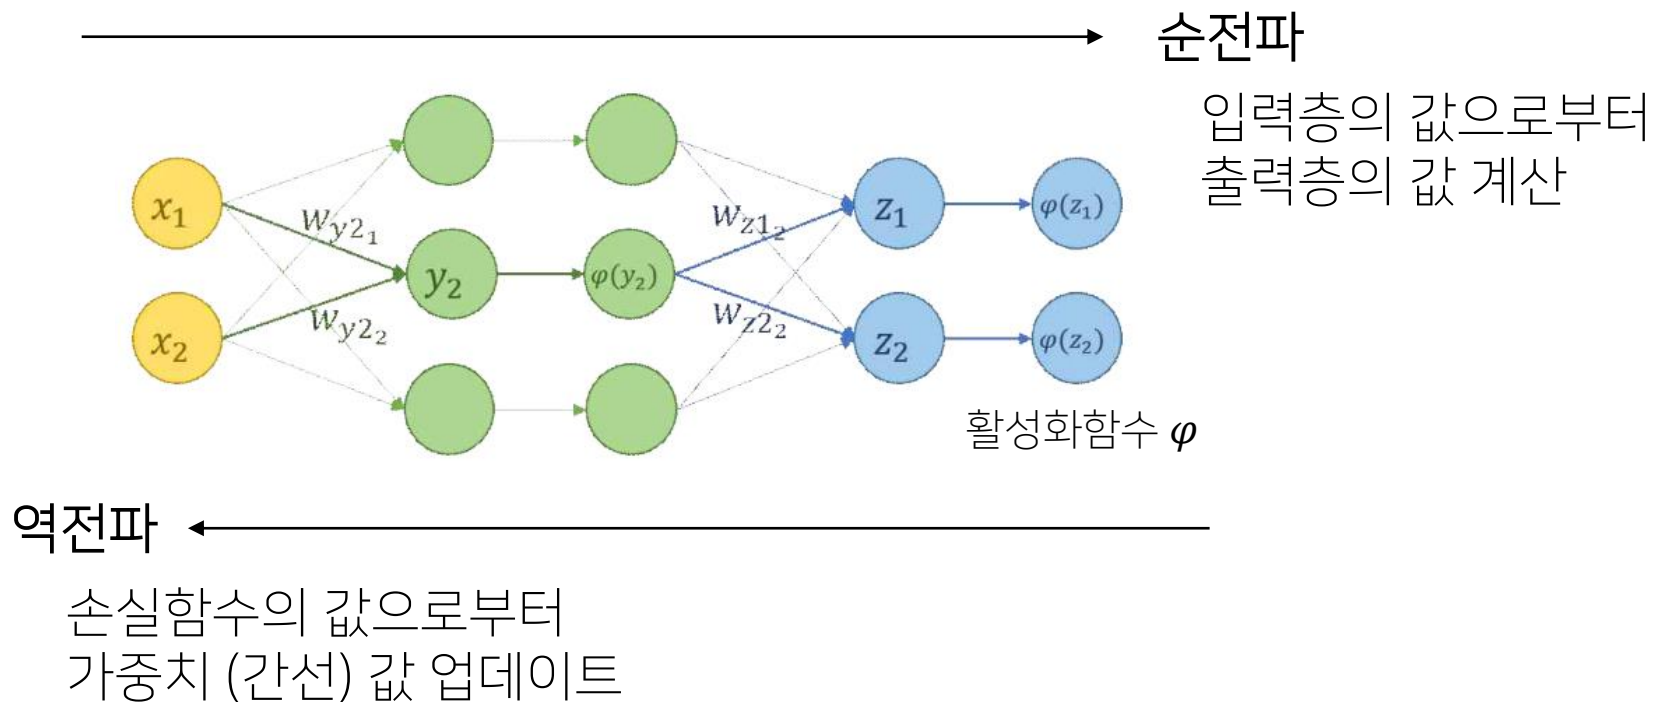
신경망의 구조

- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation



How to Calculate $\nabla \mathcal{L}(\mathbf{w}) \Big|_{\mathbf{w}=\mathbf{w}_{old}}$? Use **CHAIN RULE**

신경망의 정의

신경망의 구조

● **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Recap : Quiz 01

1. 다음 행렬곱 결과의 전치행렬을 구하여라.

$$\begin{pmatrix} 2 & 3 & 1 \\ -1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 5 \\ -2 \\ 3 \end{pmatrix}$$

- 결과 행렬의 Size : 2행 1열

☒ (7,0)

☐ (3,6)

☐ (0,7)

$$\begin{pmatrix} 2 \times 5 + 3 \times (-2) + 1 \times 3 \\ (-1) \times 5 + 2 \times (-2) + 3 \times 3 \end{pmatrix}$$

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Recap : Quiz 01

2. $f(x,y,z)=xy+yz$ 일 때, ∇f 는?

☒ $(y, x+z, y)$

☐ $(y, x+z, xy)$

☐ $(0, x, y)$

$$\begin{aligned}\nabla f &= \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right) \\ &= (y, x + z, y)\end{aligned}$$

신경망의 정의

신경망의 구조

● **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Recap : Quiz 01

3. $L(x, y) = xy, f(a, b) = (ab, a + b) = (x, y)$ 일 때, $\frac{\partial L}{\partial a}$ 를 구하시오.

Use **CHAIN RULE**

$$\frac{\partial L}{\partial a} = \frac{\partial L}{\partial x} \cdot \frac{\partial x}{\partial a} + \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial a}$$

$$= y \cdot b + x \cdot 1$$

$$= yb + x$$

신경망의 정의


신경망의 구조

- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation



$$w_{new} = w_{old} - \delta \cdot \nabla \mathcal{L}(w) \Big|_{w=w_{old}}$$

Loss Function $\mathcal{L}(w)$

신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

① w_{z1_2} : $w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$



신경망의 정의

신경망의 구조

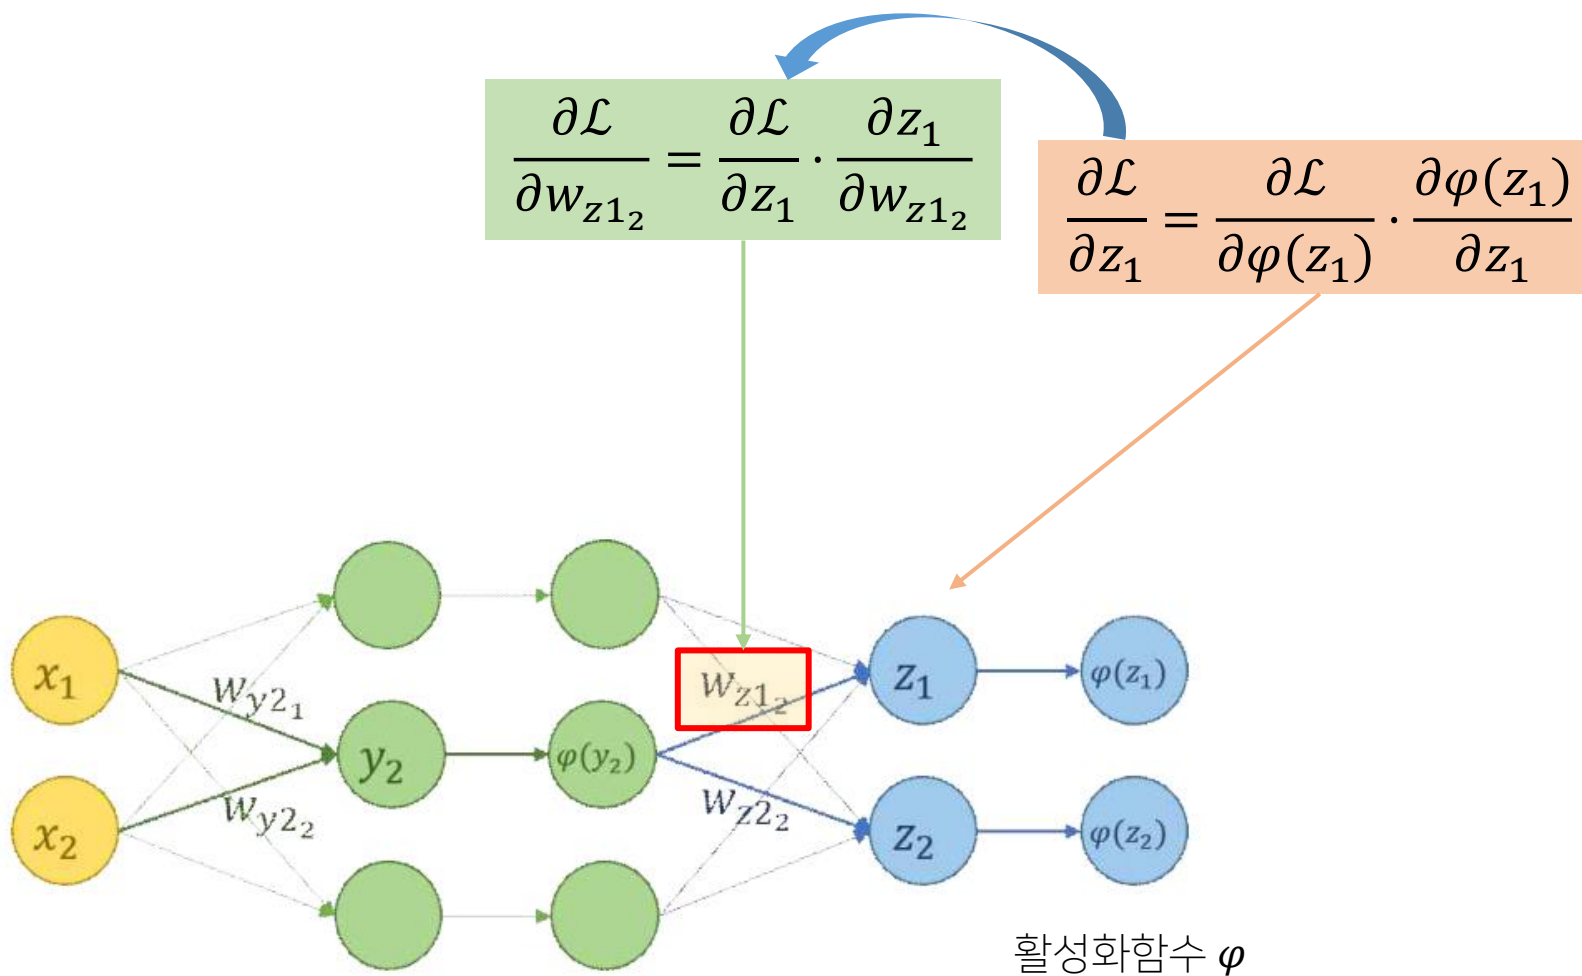
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{1} w_{z1_2} : w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$$



신경망의 정의

신경망의 구조

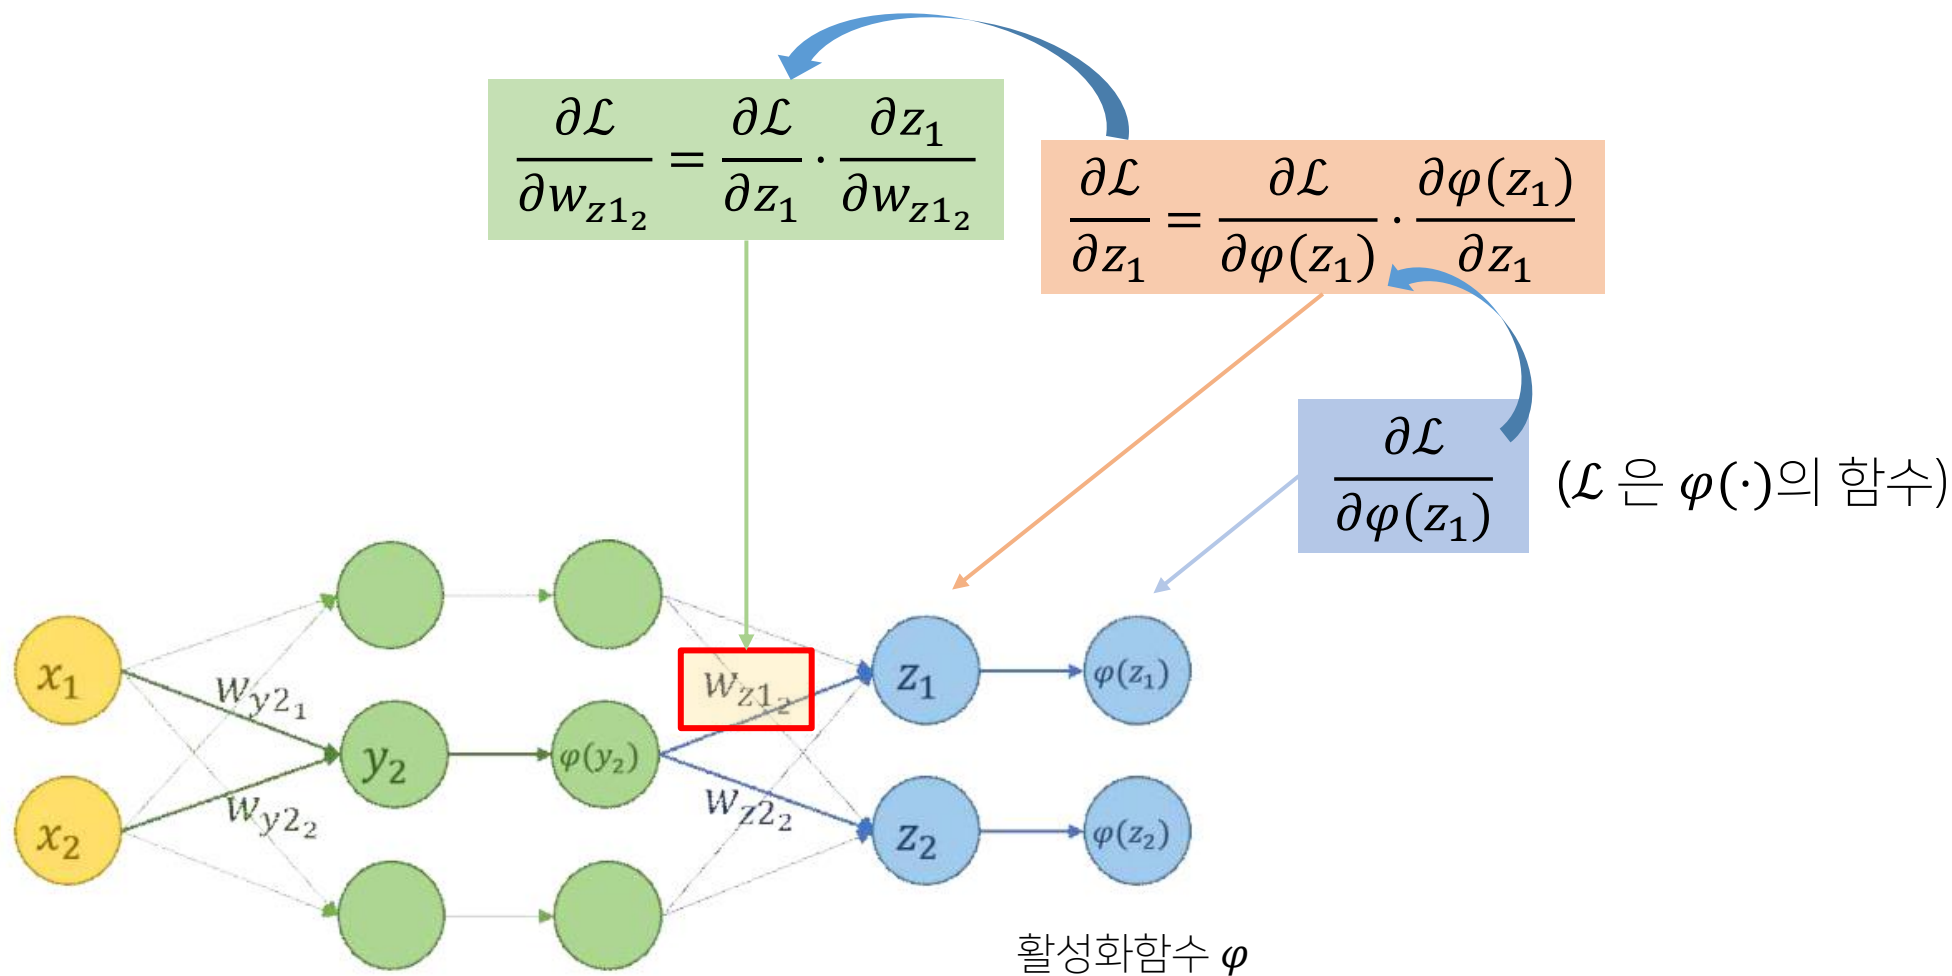
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{1} w_{z1_2} : w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$$



신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

① w_{z1_2} : $w_{z1_2 \text{ new}} = w_{z1_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z1_2 \text{ old}}}$



신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

② w_{z2_2} : $w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$



$$\frac{\partial \mathcal{L}}{\partial w_{z2_2}} = \frac{\partial \mathcal{L}}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{z2_2}}$$

신경망의 정의

신경망의 구조


신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{2} \ w_{z2_2} : w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{z2_2}} = \frac{\partial \mathcal{L}}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{z2_2}}$$

$$\frac{\partial \mathcal{L}}{\partial z_2} = \frac{\partial \mathcal{L}}{\partial \varphi(z_2)} \cdot \frac{\partial \varphi(z_2)}{\partial z_2}$$

신경망의 정의

신경망의 구조

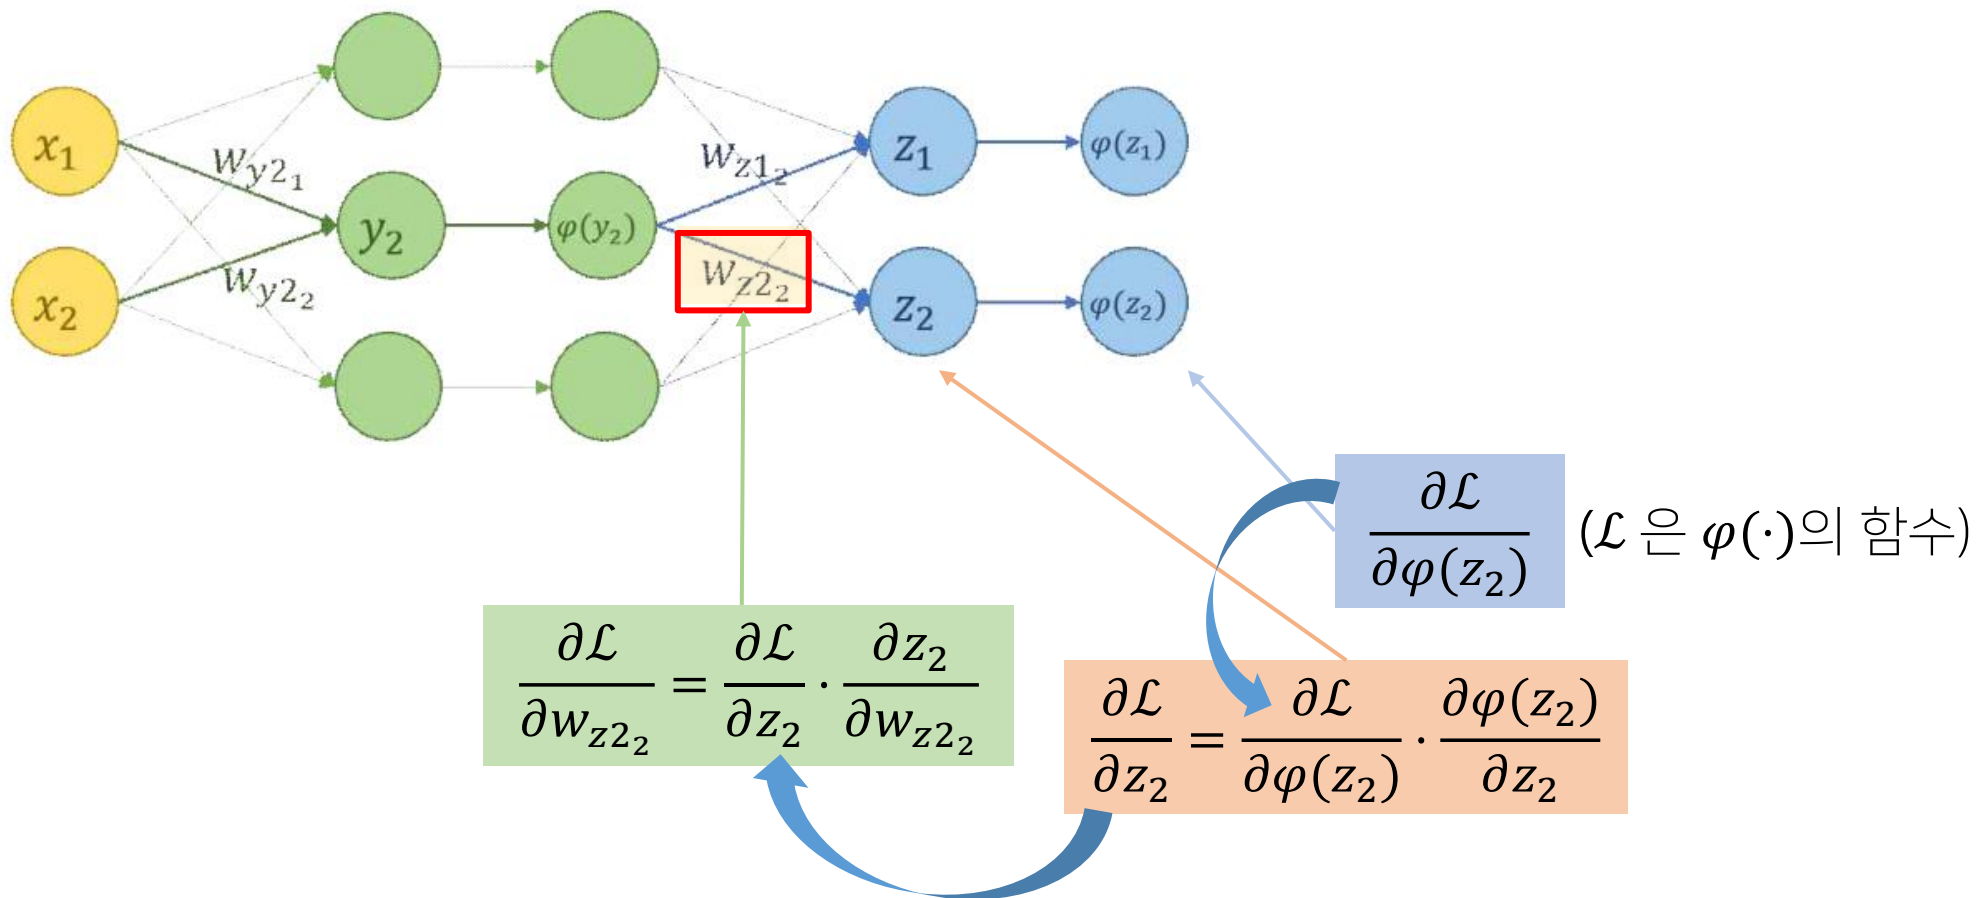
신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{2} \ w_{z2_2} : w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$$



신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{2} \ w_{z2_2} : w_{z2_2 \text{ new}} = w_{z2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{z2_2 \text{ old}}}$$



신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

③ w_{y2_2} : $w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot \frac{\partial y_2}{\partial w_{y2_2}}$$

신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

③ w_{y2_2} : $w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{3} \ w_{y2_2} : w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

$$\frac{\partial \mathcal{L}}{\partial y_2} = \frac{\partial \mathcal{L}}{\partial \varphi(y_2)} \cdot \frac{\partial \varphi(y_2)}{\partial y_2}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{3} \ w_{y2_2} : w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

$$\frac{\partial \mathcal{L}}{\partial \varphi(y_2)} = \frac{\partial \mathcal{L}}{\partial z_1} \cdot \frac{\partial z_1}{\partial \varphi(y_2)} + \frac{\partial \mathcal{L}}{\partial z_2} \cdot \frac{\partial z_2}{\partial \varphi(y_2)}$$

$$\frac{\partial \mathcal{L}}{\partial y_2} = \frac{\partial \mathcal{L}}{\partial \varphi(y_2)} \cdot \frac{\partial \varphi(y_2)}{\partial y_2}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

$$\textcircled{3} \ w_{y2_2} : w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$$



$$\frac{\partial \mathcal{L}}{\partial w_{y2_2}} = \frac{\partial \mathcal{L}}{\partial y_2} \cdot x_2$$

$$\frac{\partial \mathcal{L}}{\partial \varphi(y_2)} = \frac{\partial \mathcal{L}}{\partial z_1} \cdot w_{z1_2} + \frac{\partial \mathcal{L}}{\partial z_2} \cdot w_{z2_2}$$

$$\frac{\partial \mathcal{L}}{\partial y_2} = \frac{\partial \mathcal{L}}{\partial \varphi(y_2)} \cdot \frac{\partial \varphi(y_2)}{\partial y_2}$$

신경망의 정의

신경망의 구조

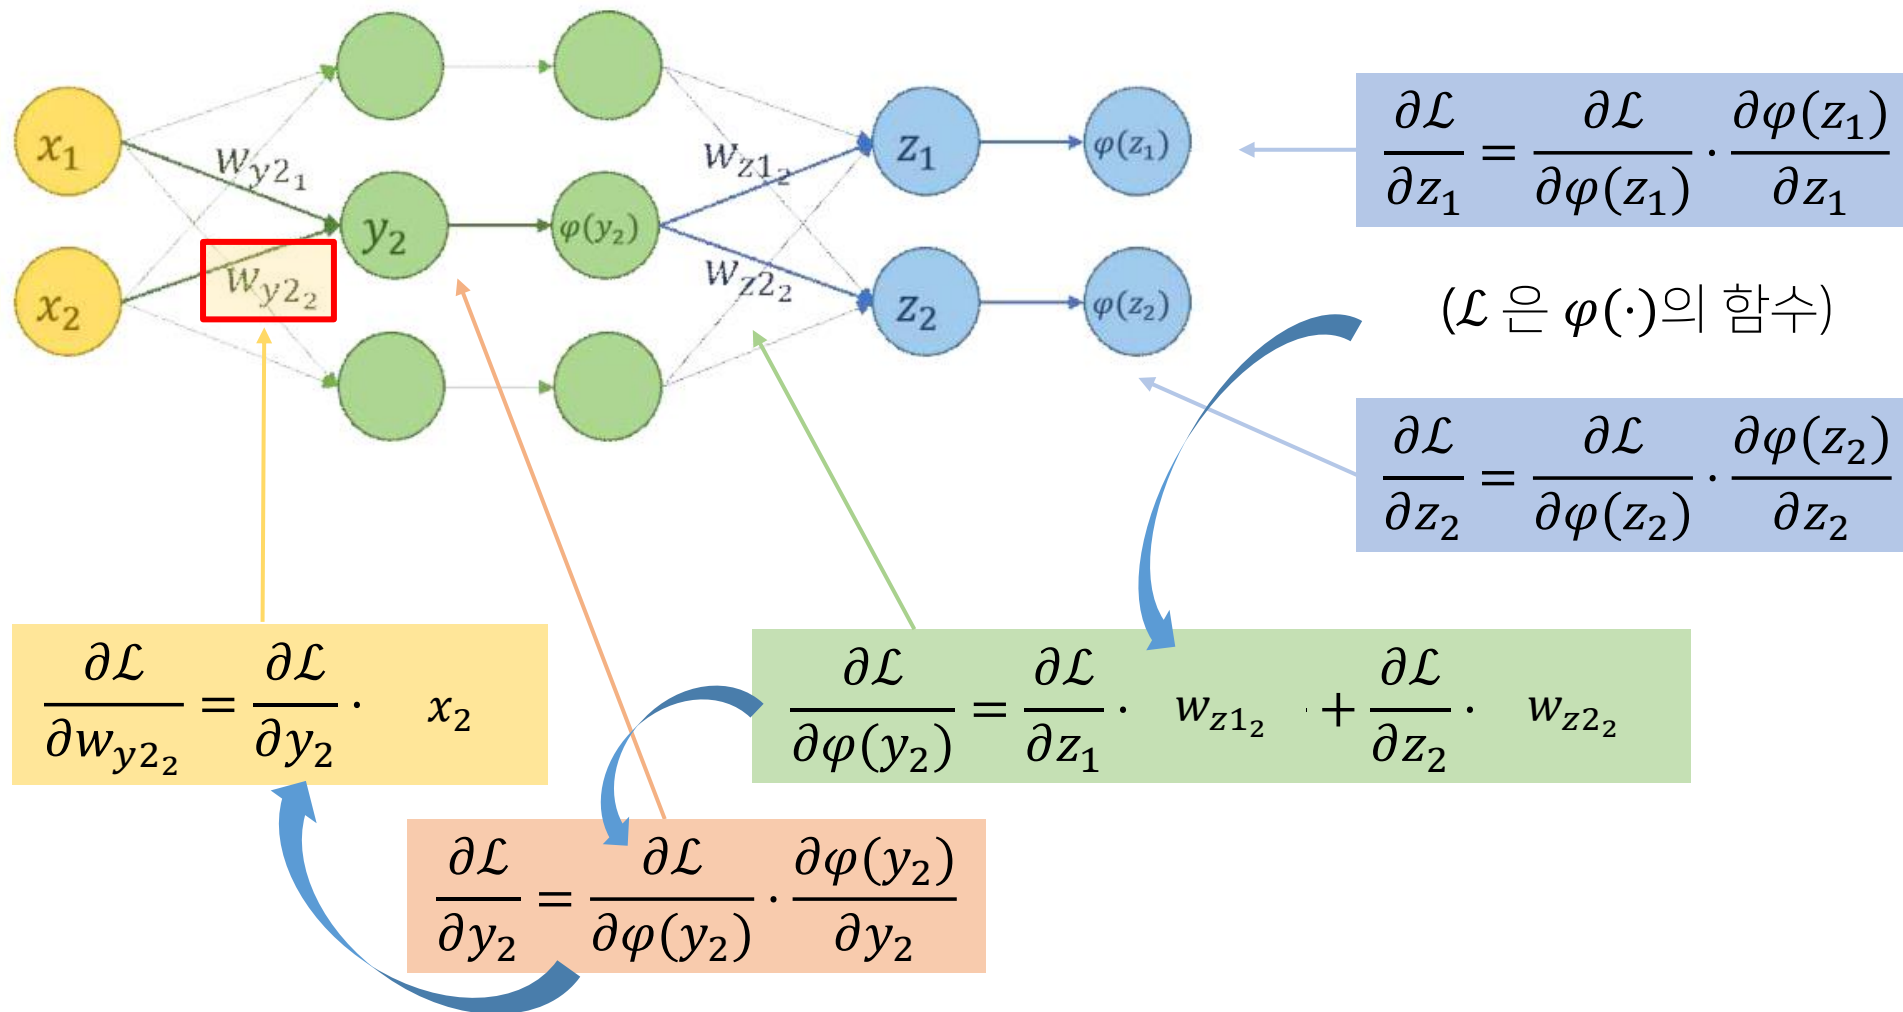
신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

③ w_{y2_2} : $w_{y2_2 \text{ new}} = w_{y2_2 \text{ old}} - \delta \cdot \nabla \mathcal{L}(w)|_{w=w_{y2_2 \text{ old}}}$



신경망의 정의

신경망의 구조

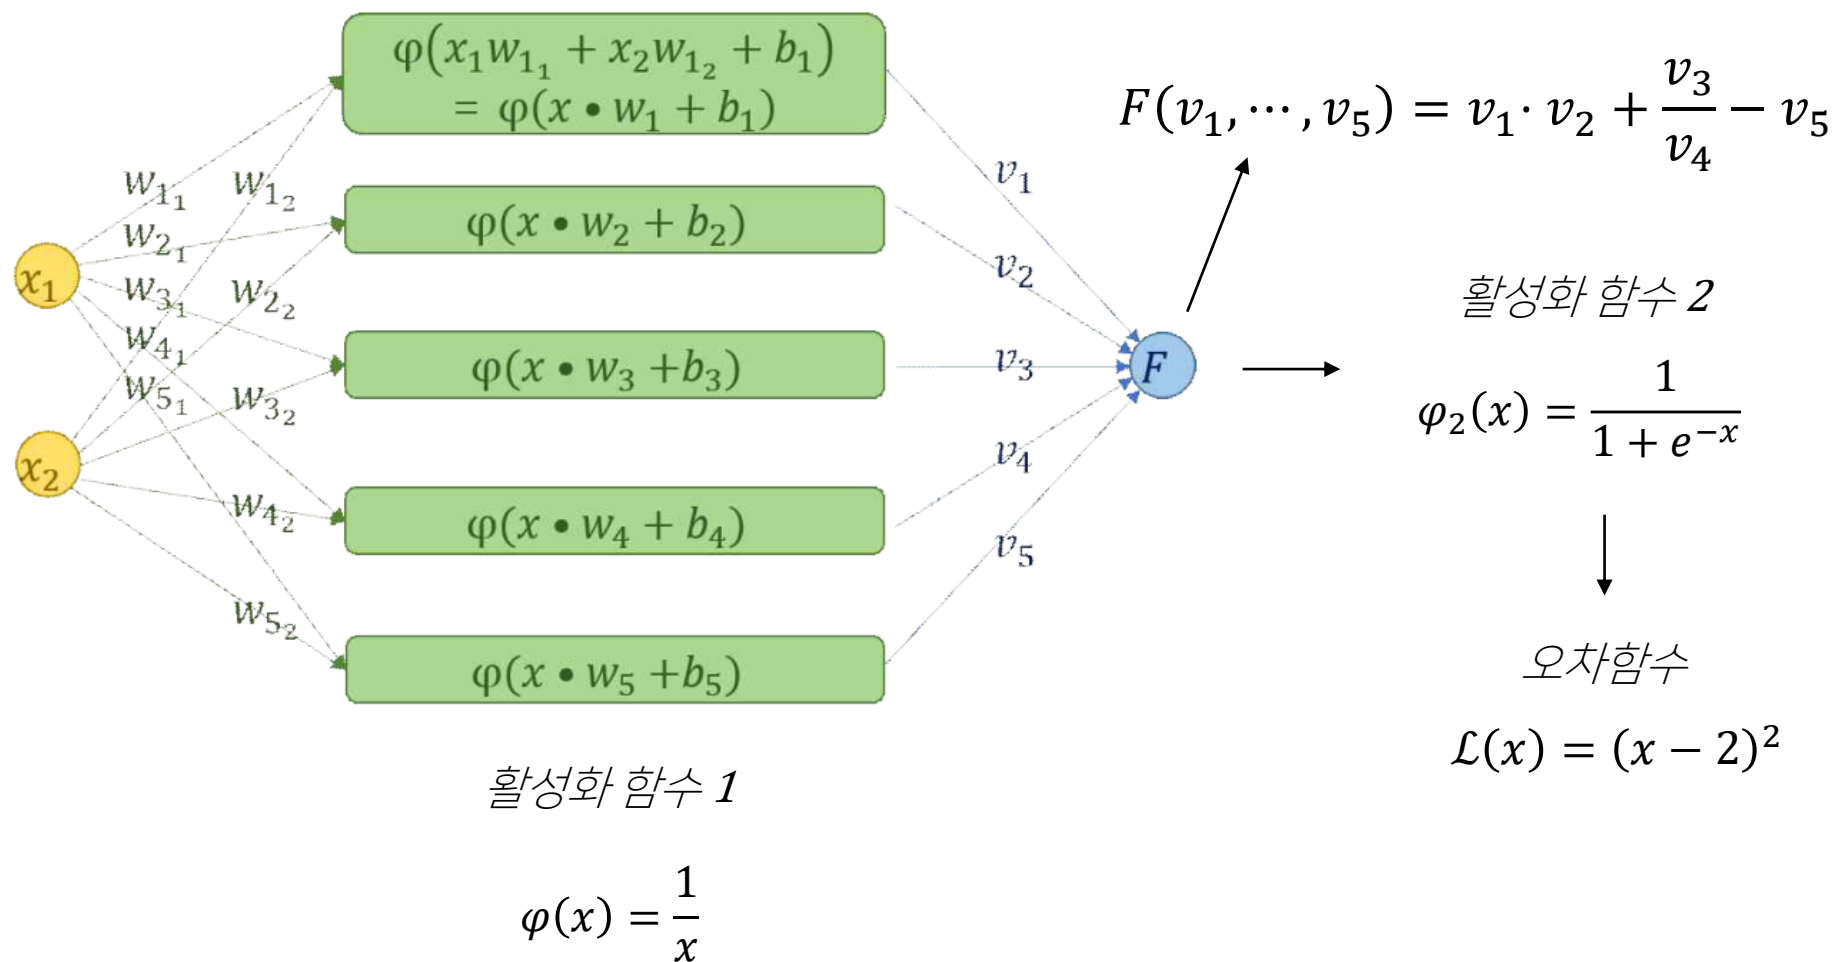
● 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



신경망의 정의

신경망의 구조


- 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

활성화 함수 1: $\varphi(x) = \frac{1}{x}$

활성화 함수 2: $\varphi_2(x) = \frac{1}{1+e^{-x}}$

오차함수: $\mathcal{L}(x) = (x - 2)^2$

What is $\frac{\partial \mathcal{L}}{\partial w_{52}}$?

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot \frac{\partial u}{\partial w_{5_2}}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \frac{\partial \varphi(u)}{\partial u}$$

신경망의 정의

신경망의 구조

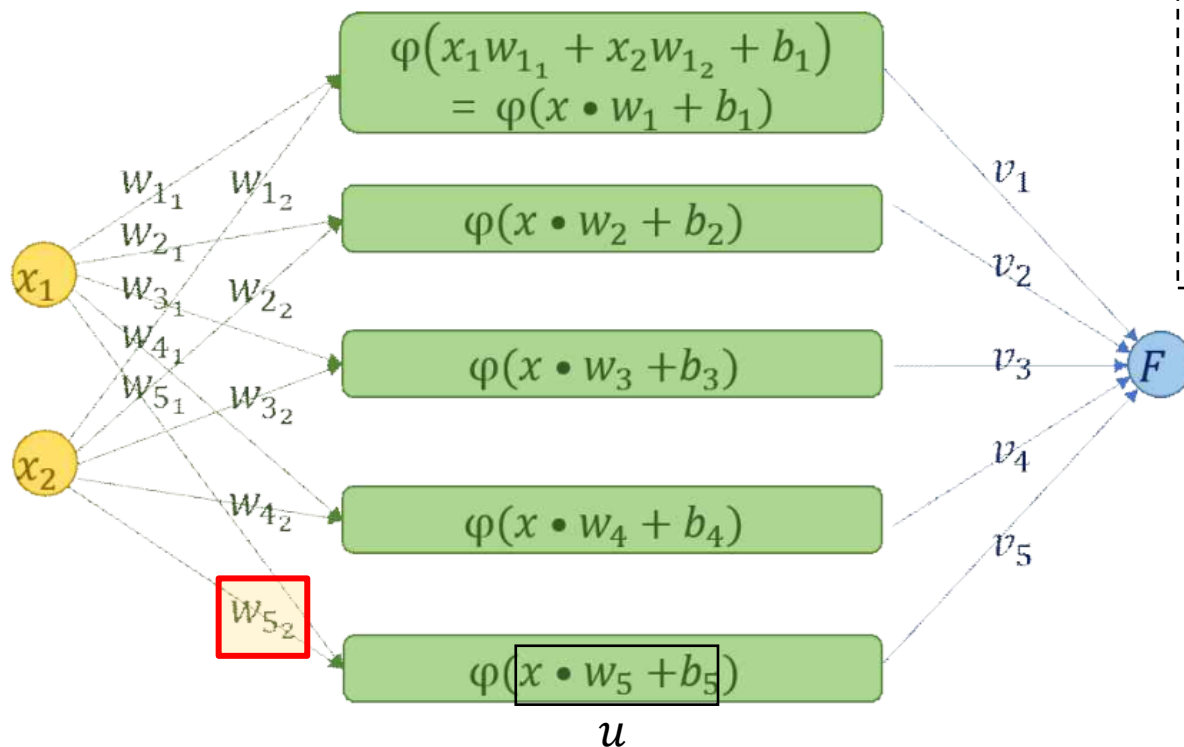
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1 : } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2 : } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수 : } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

신경망의 정의

신경망의 구조

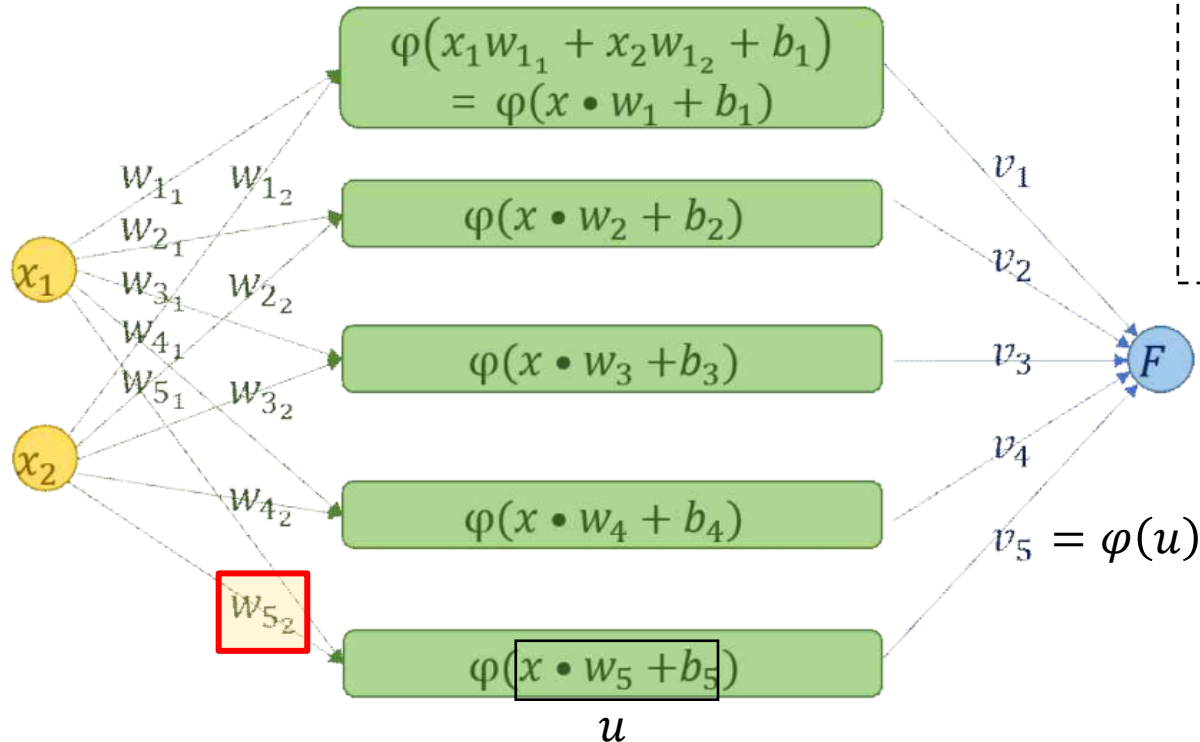
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot \frac{\partial F}{\partial \varphi(u)}$$

신경망의 정의

신경망의 구조


• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1: } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2: } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수: } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

신경망의 정의

신경망의 구조

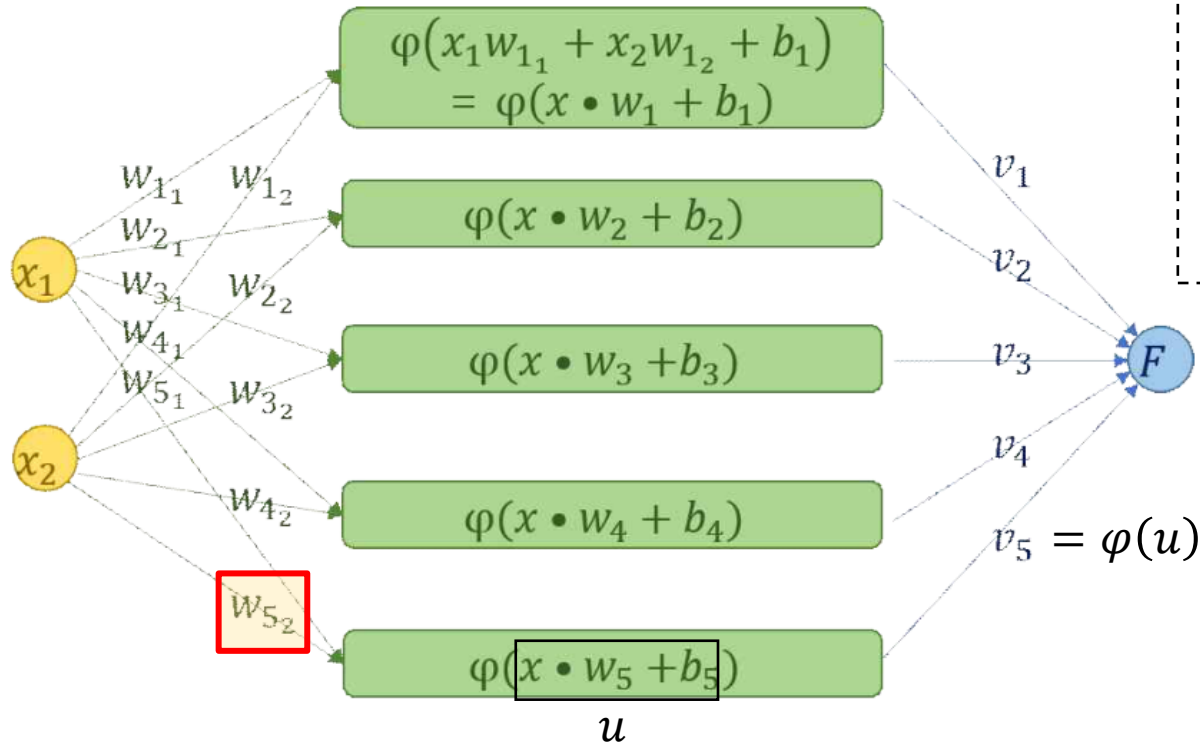
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

활성화 함수 1 : $\varphi(x) = \frac{1}{x}$

활성화 함수 2 : $\varphi_2(x) = \frac{1}{1+e^{-x}}$

오차함수 : $\mathcal{L}(x) = (x - 2)^2$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot \frac{\partial \varphi_2(F)}{\partial F}$$

신경망의 정의

신경망의 구조

- **신경망의 학습**

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Sigmoid 함수 미분

$$\varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\frac{\partial \varphi_2(x)}{\partial x} = \frac{-e^{-x}}{(1+e^{-x})^2} = (1 - \varphi_2(x)) \cdot \varphi_2(x)$$

신경망의 정의

신경망의 구조

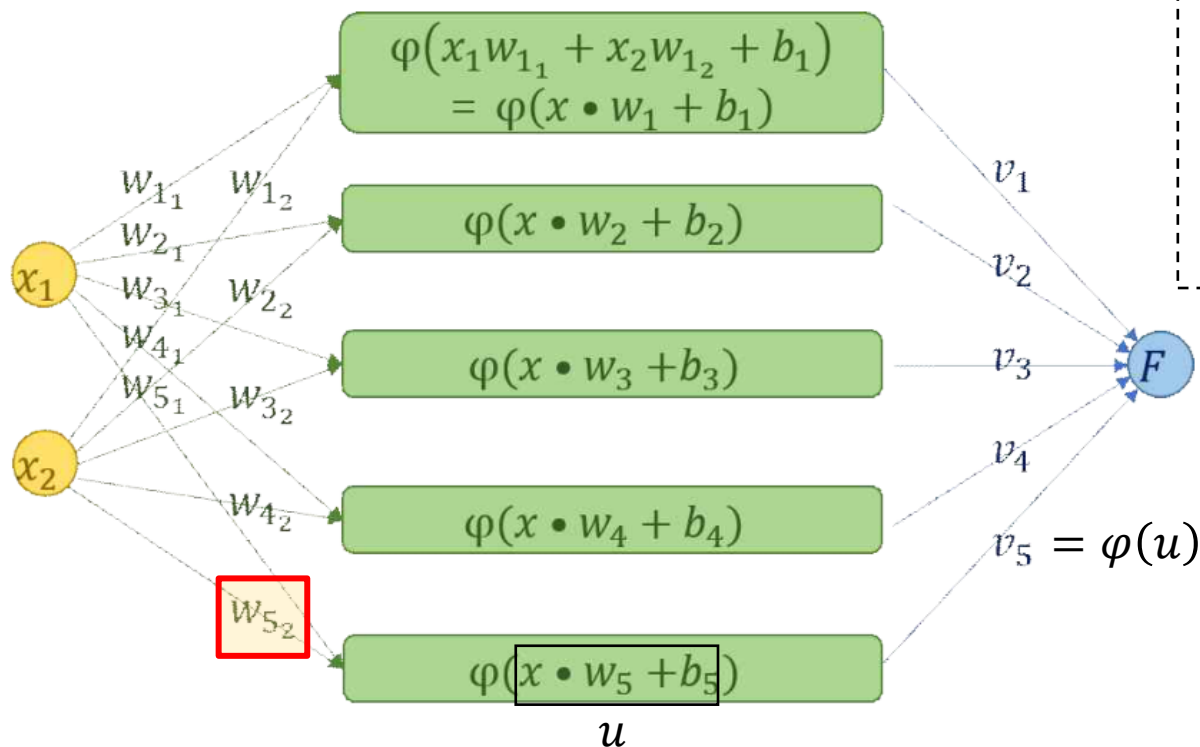
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1 : } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2 : } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수 : } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

신경망의 정의

신경망의 구조

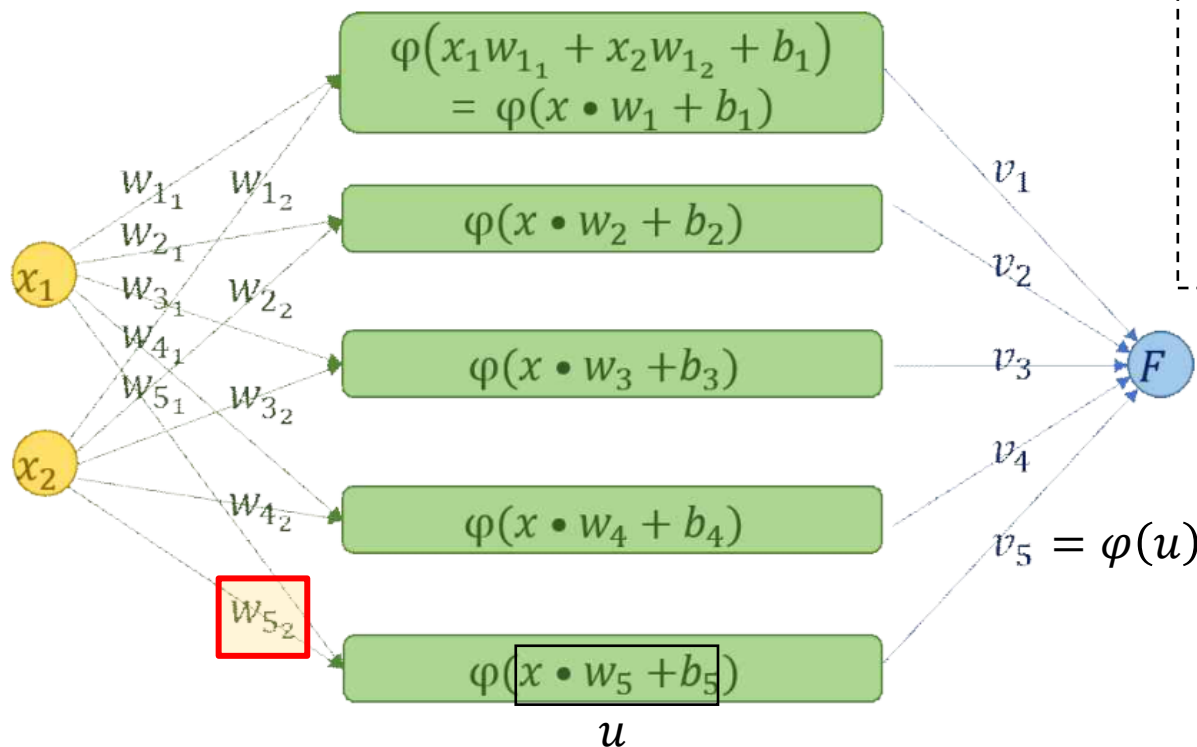
• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example



$$F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

$$\text{활성화 함수 1 : } \varphi(x) = \frac{1}{x}$$

$$\text{활성화 함수 2 : } \varphi_2(x) = \frac{1}{1+e^{-x}}$$

$$\text{오차함수 : } \mathcal{L}(x) = (x - 2)^2$$

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2} \right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

$$\textcircled{6} \quad F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

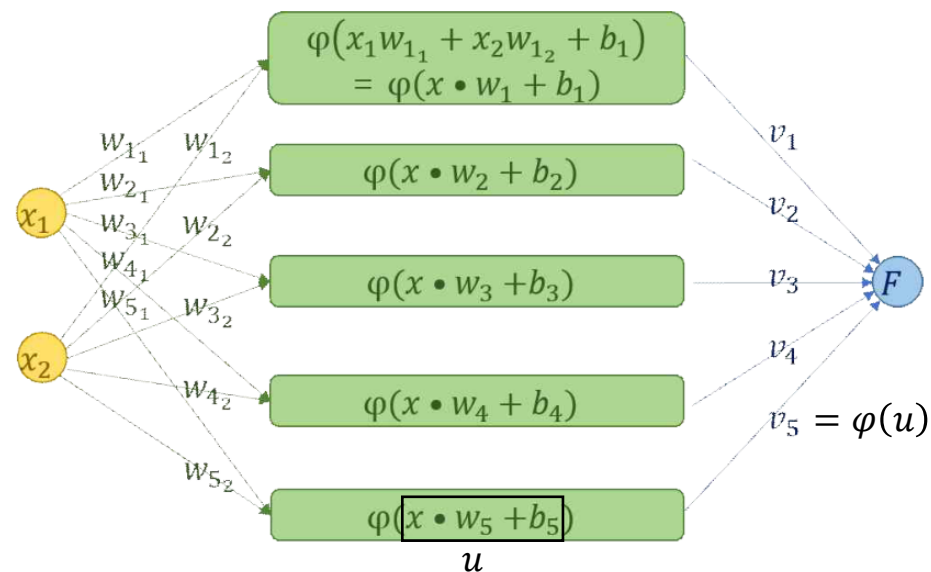
$$\textcircled{7} \quad \varphi(x) = \frac{1}{x}$$

$$\textcircled{8} \quad \varphi_2(x) = \frac{1}{1 + e^{-x}}$$

$$\textcircled{9} \quad \mathcal{L}(x) = (x - 2)^2$$

⑩

w_{1_1}	0.1	w_{2_1}	1.1
w_{1_2}	0.5	w_{2_2}	0.0
w_{1_3}	0.3	w_{2_3}	0.4
w_{1_4}	2.1	w_{2_4}	-0.1
w_{1_5}	-0.2	w_{2_5}	1.3
x_1	1.7	x_2	3.5



신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{52}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

$$\textcircled{6} \quad F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$

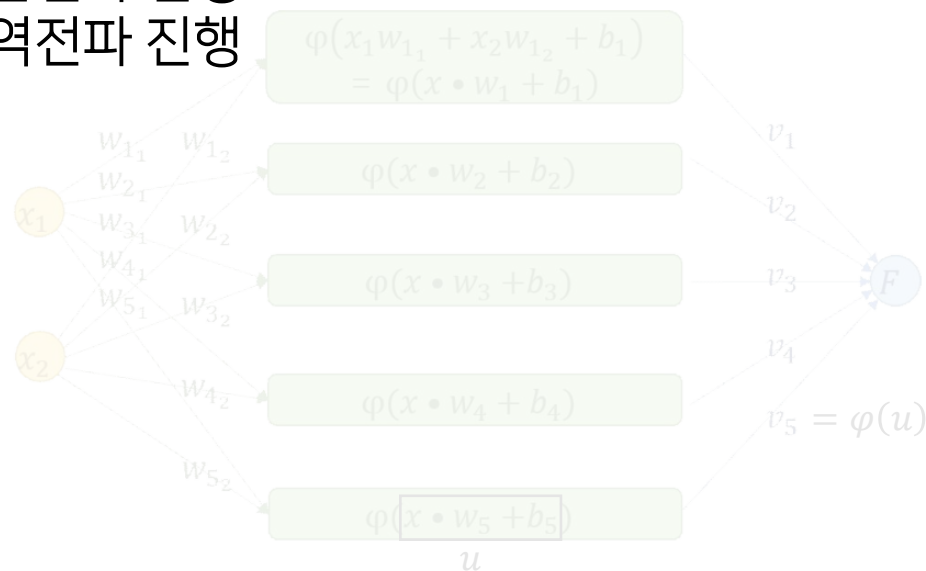
$$\textcircled{7} \quad \varphi(x) = \frac{1}{x}$$

$$\textcircled{8} \quad \varphi_2(x) = \frac{1}{1 + e^{-x}}$$

연산 순서:
(1) 순전파 진행
(2) 역전파 진행

⑩

w_{11}	0.1	w_{21}	1.1
w_{12}	0.5	w_{22}	0.0
w_{13}	0.3	w_{23}	0.4
w_{14}	2.1	w_{24}	-0.1
w_{15}	-0.2	w_{25}	1.3
x_1	1.7	x_2	3.5



신경망의 정의

신경망의 구조

신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

(1) 순전파 진행

$$\textcircled{1} \quad \frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$$

$$\textcircled{2} \quad \frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$$

$$\textcircled{3} \quad \frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$$

$$\textcircled{4} \quad \frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$$

$$\textcircled{5} \quad \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$$

$$\textcircled{6} \quad F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$$


$$\textcircled{7} \quad \varphi(x) = \frac{1}{x}$$

$$\textcircled{8} \quad \varphi_2(x) = \frac{1}{1 + e^{-x}}$$

$$\textcircled{9} \quad \mathcal{L}(x) = (x - 2)^2$$

⑩

w_{1_1}	0.1	w_{2_1}	1.1
w_{1_2}	0.5	w_{2_2}	0.0
w_{1_3}	0.3	w_{2_3}	0.4
w_{1_4}	2.1	w_{2_4}	-0.1
w_{1_5}	-0.2	w_{2_5}	1.3
x_1	1.7	x_2	3.5



신경망의 정의

신경망의 구조

• 신경망의 학습

순전파와 역전파
반복

Hyper-
parameter

Backpropagation

Another Example

① $\frac{\partial \mathcal{L}}{\partial w_{5_2}} = \frac{\partial \mathcal{L}}{\partial u} \cdot x_2$

② $\frac{\partial \mathcal{L}}{\partial u} = \frac{\partial \mathcal{L}}{\partial \varphi(u)} \cdot \left(-\frac{1}{u^2}\right)$

③ $\frac{\partial \mathcal{L}}{\partial \varphi(u)} = \frac{\partial \mathcal{L}}{\partial F} \cdot (-1)$

④ $\frac{\partial \mathcal{L}}{\partial F} = \frac{\partial \mathcal{L}}{\partial \varphi_2(F)} \cdot (1 - \varphi_2(F)) \cdot \varphi_2(F)$

⑤ $\frac{\partial \mathcal{L}}{\partial \varphi_2(F)} = 2(\varphi_2(F) - 2)$

⑥ $F(v_1, \dots, v_5) = v_1 \cdot v_2 + \frac{v_3}{v_4} - v_5$

(2) 역전파 진행


⑦ $\varphi(x) = \frac{1}{x}$

⑧ $\varphi_2(x) = \frac{1}{1 + e^{-x}}$

⑨ $\mathcal{L}(x) = (x - 2)^2$

⑩

w_{1_1}	0.1	w_{2_1}	1.1
w_{1_2}	0.5	w_{2_2}	0.0
w_{1_3}	0.3	w_{2_3}	0.4
w_{1_4}	2.1	w_{2_4}	-0.1
w_{1_5}	-0.2	w_{2_5}	1.3
x_1	1.7	x_2	3.5



The background is a light blue gradient with a white diagonal line. Various geometric shapes and lines are scattered across the page, including circles, squares, triangles, and lines in different colors (white, yellow, pink, green).

5. 순전파와 역전파의 반복

<머신러닝 첫 단추 끼우기>
4.4.절

신경망의 정의

신경망의 구조


신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

1 Iteration 의 정의

- 데이터 집합에 대해 순전파, 역전파를 통해 가중치 업데이트가 **1회** 일어나는 것



- 신경망에 1개의 Data씩 입력해줄 때 (Data 총 개수 : N개)
 - 전체 데이터에 대해 가중치 업데이트를 하기 위해 N iteration 필요
- 신경망에 모든 Data를 한 번에 입력할 때
 - 전체 데이터에 대해 가중치 업데이트를 하기 위해 1 iteration 필요

신경망의 정의

신경망의 구조

신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

실제 신경망에서는?

- N개의 전체 데이터를 M개씩 묶어 신경망에 입력

Batch (배치) / Batch Size

- Batch : 한 번에 신경망에 입력하는 데이터 묶음
- Batch Size : 1개의 Batch 내의 데이터 수 (= M)
- N개의 Data를 랜덤하게 섞고, M개씩 골라 Batch 생성



신경망의 정의


신경망의 구조

신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

Batch에서의 순전파와 역전파



- 순전파 : 각 batch를 이루는 데이터에 대해 독립적으로 진행
- 역전파 : 각 batch에서 계산된 손실함수의 평균을 이용해 진행
- More Details on ML LAB 5! (Next Seminar)

신경망의 정의


신경망의 구조

신경망의 학습

● 순전파와 역전파
반복

Hyper-
parameter

1 epoch 의 정의



- 전체 데이터에 대해 순전파, 역전파를 통해 가중치 업데이트가 **1회** 일어나는 것

Q) 전체 데이터가 D 개, Batch Size가 M 일 때

- Batch 의 개수는? **D/M**
- 1 epoch 는 몇 iteration으로 이루어져 있는가? **D/M**

Batch 를 사용하는 이유?

In Next Seminar!

The background is a light blue gradient with a white diagonal line. Various geometric shapes and lines are scattered across the page, including circles, squares, triangles, and wavy lines in different colors like green, yellow, and red.

6. Hyperparameter

<머신러닝 첫 단추 끼우기>
4.5.절

신경망의 정의

신경망의 구조

신경망의 학습

순전파와 역전파
반복

● **Hyper-
parameter**

What is Hyperparameter?

- 딥러닝 모델의 성능에 영향을 주는 변수
- 사용자가 직접 설정해 입력하며, 학습 과정에서는 변화하지 않음
- “Parameter (가중치)를 효과적으로 업데이트 해 주기 위한 요소”

- Examples

- 가중치의 초기값
- Learning rate
- 학습의 종료조건
- Layer Depth
- Numbers of nodes in 1 Layer
- Activation Function
- Loss Function
- Optimizer
- batch size

7. Summary

Summary

- 수학적 모델을 신경망으로 근사할 수 있음
- 신경망 간선에 들어가는 가중치 및 편향의 적절한 값을 찾는 것이 해야할 일 (학습)
- 우선 파라미터 값을 적당히 초기화한 후, 순전파 결과를 도출하고 손실함수를 통해 그 결과가 얼마나 좋은지 평가
- “손실함수 값을 작게 하려면 파라미터 값을 어떻게 변화시킬까?” 에 대한 답을 주는 것이 경사하강법
- 가중치 및 편향에 대한 미분값을 구하는 역전파 과정에서 연쇄법칙을 사용